PROJET 12 · DATA ANALYST

Détection automatique de faux billets

Mission ONCFM · Restitution des résultats à Marie, responsable de la lutte contre le faux-monnayage

Sabah Rizki · Senior Data Analyst · Octobre 2026

Objectif : laisser passer le moins de faux billets possible

La demande

- Une machine mesure 6 dimensions de chaque billet (mm)
- Prédire « vrai » ou « faux » à partir de ces seules mesures
- Comparer 4 méthodes : régression logistique, KNN, Random Forest, K-means
- Livrer une application : un billet ou un fichier CSV en entrée, une réponse binaire en sortie

Les deux erreurs possibles

Faux négatif

Un faux billet classé « vrai » repart en circulation : erreur la plus grave

Faux positif

Un vrai billet classé « faux » : coûte une vérification manuelle

Une démarche en six étapes

1 Contrôle qualité

types, manquants, doublons

2 Exploration

distributions, corrélations, tests, ACP

3 Valeurs manquantes

régression linéaire

4 Prétraitement

train / test, standardisation

5 4 modèles

réglage par validation croisée

6 Choix & application

pipeline sauvegardé, script

Des données propres, conformes au cahier des charges

1 500
billets scannés,
6 mesures en mm

1 000
vrais billets
et 500 faux (2/3 – 1/3)

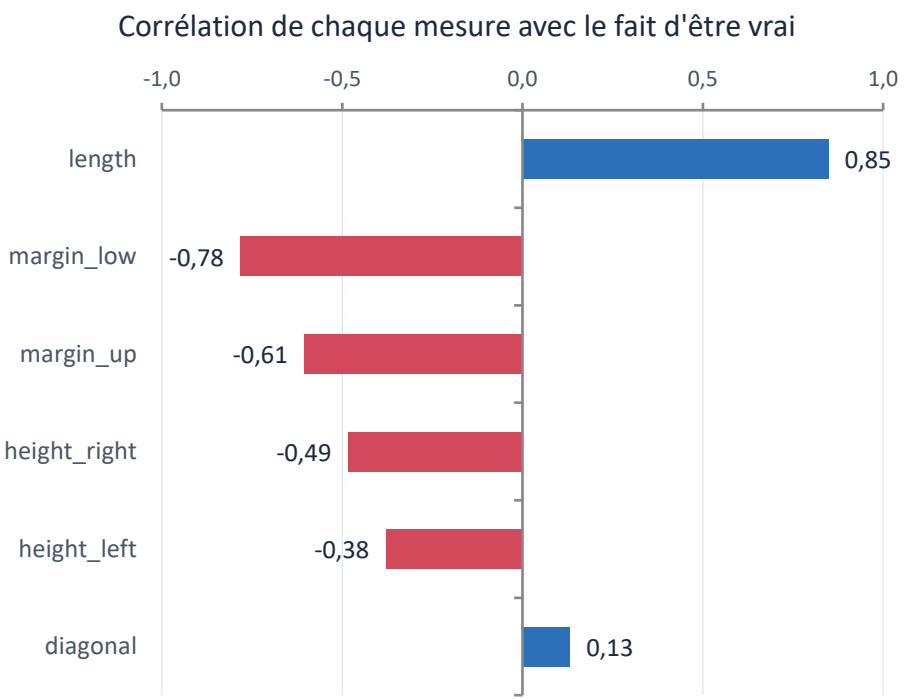
37
valeurs manquantes,
toutes sur margin_low
(2,5 %)

0
doublon,
aucune valeur aberrante

Ce qu'il faut en retenir

- Classes déséquilibrées : un modèle qui dirait toujours « vrai » aurait déjà 66,7 % de bonnes réponses → l'accuracy seule est trompeuse
- D'où un découpage stratifié et des métriques centrées sur les faux billets (rappel, précision)
- Valeurs atypiques conservées : mesures physiques plausibles, souvent… des faux billets

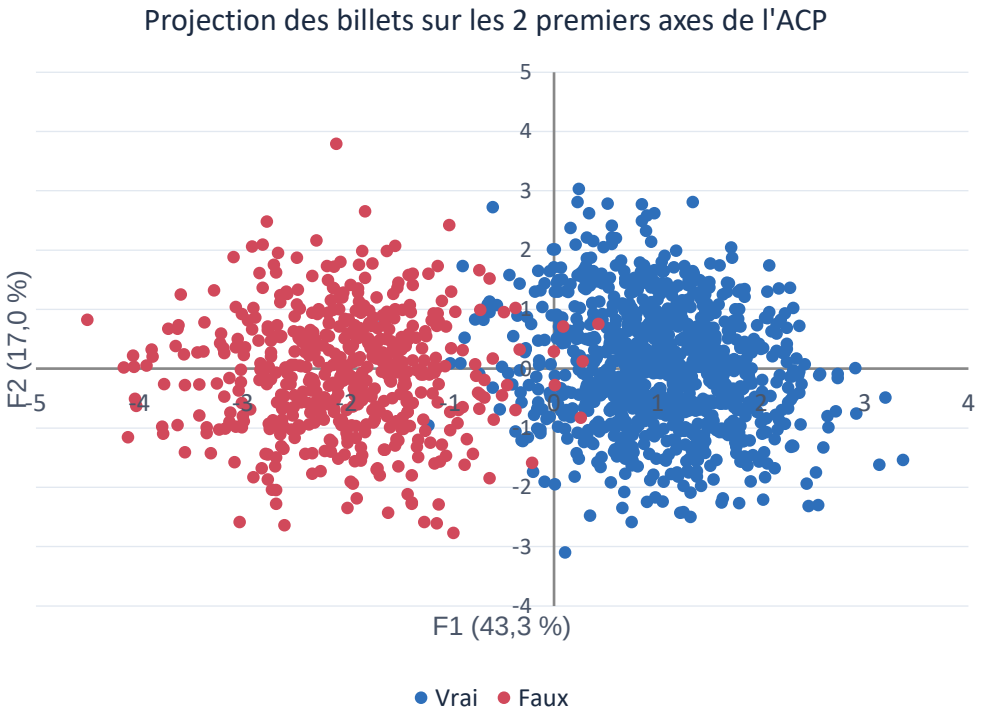
Longueur et marges trahissent les faux billets



Moyenne (mm)	Vrais	Faux
length	113,20	111,63
margin_low	4,12	5,21
margin_up	3,05	3,35
height_right	103,81	104,14
height_left	103,95	104,19
diagonal	171,99	171,90

Les faux billets sont plus courts (≈ 1,6 mm) et ont des marges plus grandes. Les 6 écarts sont significatifs (Mann-Whitney, $p < 0,05$), mais celui de la diagonale est minime (< 0,1 mm).

Deux familles de billets presque parfaitement séparées



43,3 %

de l'information résumée par le 1er axe (F1)

- F1 oppose la longueur aux marges et hauteurs : c'est l'axe « vrai ↔ faux »
- F2 est porté par la diagonale, qui ne sépare pas les groupes
- Groupes quasi linéairement séparables : un modèle simple peut suffire

37 marges manquantes complétées par régression linéaire

Pourquoi pas la moyenne ?

- margin_low a deux « bosses » (vrais ≈ 4,1 mm, faux ≈ 5,2 mm) : la moyenne (≈ 4,5) ne correspond à aucun groupe

Méthode retenue

- margin_low prédite par les 5 autres mesures (statsmodels), toutes significatives ($p < 0,05$)
- Sans utiliser vrai/faux : en production, c'est justement l'inconnue
- Intégrée au pipeline : apprise sur le train seul, et capable de compléter une mesure manquante en production

0,48 — R^2 : la régression explique ≈ la moitié de la variance

< 1,6 — VIF max : aucune colinéarité gênante

– 28 % — d'erreur d'imputation vs la moyenne (RMSE en validation croisée)

Un protocole qui garantit une évaluation honnête



- Découpage stratifié (random_state = 42) : 1/3 de faux dans chaque jeu
- Hyperparamètres réglés par validation croisée à 5 plis sur le train (GridSearchCV, critère F1)
- Standardisation (moyenne 0, écart-type 1) : indispensable pour KNN, K-means et régression logistique
- Pipeline unique : imputation → standardisation → modèle, ajusté sur le train uniquement

Régression logistique : 121 faux sur 125, zéro fausse alerte

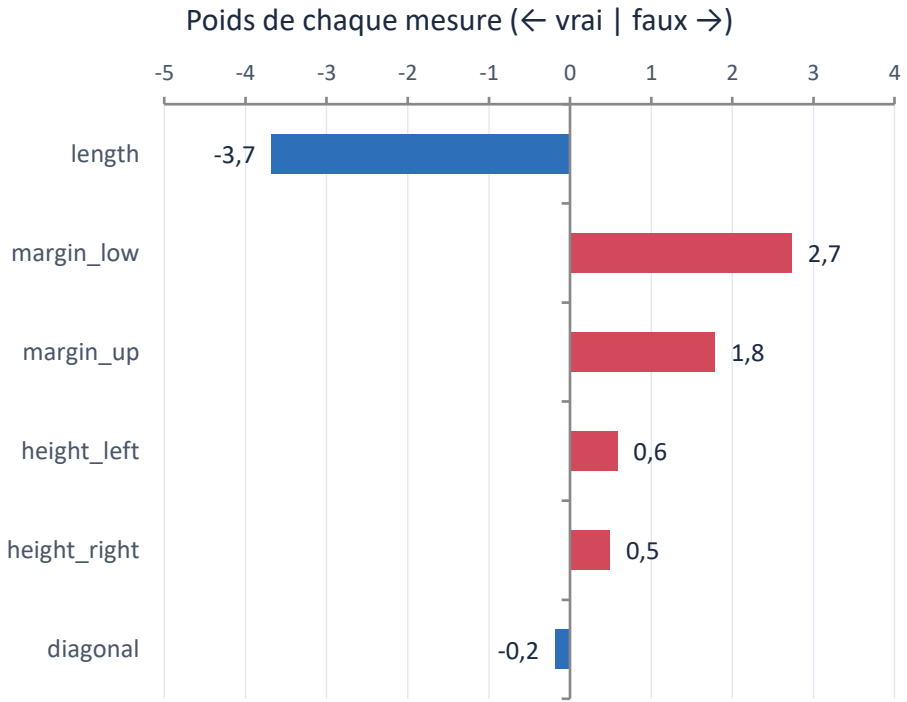
Matrice de confusion (test)

	Prédit vrai	Prédit faux
Réel vrai	250	0
Réel faux	4	121

Rappel 96,8 % · Précision 100,0 % · AUC 0,996

Calcule une probabilité d'être faux (sigmoïde) ; « faux » si ≥ 0,5

Réglage : C = 1, max_iter = 1000



KNN et Random Forest : des performances du même niveau

KNN (k = 3)

	Prédit vrai	Prédit faux
Réel vrai	250	0
Réel faux	4	121

Rappel 96,8 % · Précision 100,0 %

- Vote des 3 billets les plus proches. Stable de k = 3 à 29 ; k = 1 sur-apprend
- Limite : « probabilité » en escalier (0, 1/3, 2/3, 1) et tout le jeu d'entraînement à garder en mémoire

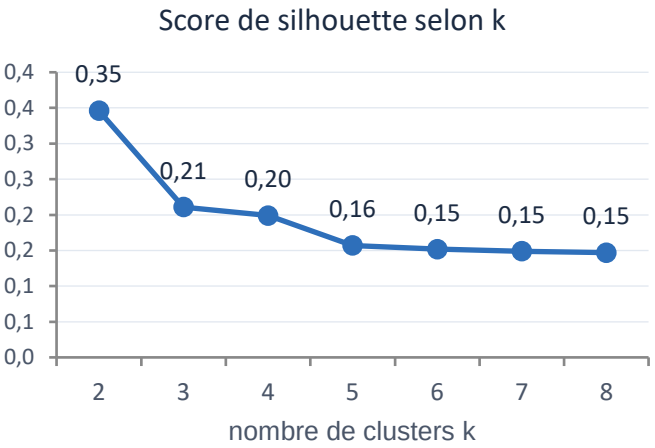
Random Forest (300 arbres)

	Prédit vrai	Prédit faux
Réel vrai	249	1
Réel faux	5	120

Rappel 96,0 % · Précision 99,2 %

- Vote de 300 arbres de décision. Importance : length 0,46, margin_low 0,33, margin_up 0,12
- Limite : modèle lourd et peu explicable (« boîte noire »)

K-means : sans étiquettes, il retrouve vrais et faux



Train	Réel vrai	Réel faux
Cluster « vrai »	741	10
Cluster « faux »	9	365

Prédiction par centroïdes (test)

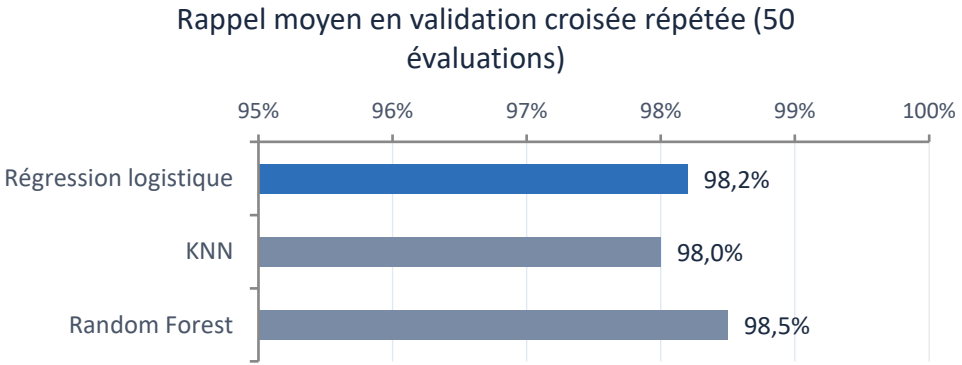
	Prédit vrai	Prédit faux
Réel vrai	**249**	**1**
Réel faux	**4**	**121**

Rappel 96,8 % · Précision 99,2 %

- Non supervisé : regroupe les billets sans connaître leur nature
- k = 2 justifié par la silhouette maximale (0,35)
- Cluster « faux » : plus court, marges plus grandes
- Nouveau billet → centroïde le plus proche
- Pas un classifieur : confirme la structure, n'optimise pas la détection

4 modèles excellents, séparés par 1 ou 2 billets

Jeu de test (375)	Rappel	Précision	F1	AUC	Faux ratés	Fausses alertes
Régression logistique	**96,8 %**	**100,0 %**	**0,984**	0,996	**4**	**0**
KNN	**96,8 %**	**100,0 %**	**0,984**	0,984	**4**	**0**
Random Forest	96,0 %	99,2 %	0,976	**0,998**	5	1
K-means	**96,8 %**	99,2 %	0,980	0,993	**4**	1



Lecture

Écarts de rappel entre modèles (≤ 0,5 point) bien inférieurs à leur variabilité (écart-type ≈ 1,4 points) : aucun modèle n'est significativement meilleur.

Modèle retenu : la régression logistique

Performante

Au meilleur niveau sur le test (0 fausse alerte) et dans la marge des autres en validation croisée

Explicable

Ses coefficients disent pourquoi un billet est jugé faux : un atout pour justifier une saisie

Probabilités fiables

Une vraie probabilité par billet, pour confirmer la décision et organiser le contrôle manuel

Simple et robuste

Léger, rapide, peu de risque de sur-apprentissage ; adapté à des groupes linéairement séparables

Les probabilités confirment et ciblent les contrôles

93,9 %

des billets du test ont une probabilité très tranchée (< 0,05 ou > 0,95)

4,5 %

des billets à contrôler avec la zone 0,1 – 0,9 (fixée sur le train)

9 / 10

erreurs du train captées par cette zone de contrôle

Les 4 faux billets ratés sur le test

- 2 à la frontière (probabilités ≈ 0,19 et 0,21) : signalés par la zone de contrôle
- 2 aux mesures typiques d'un vrai (≈ 0,003 et 0,05) : indétectables avec ces 6 mesures
- Abaisser le seuil à 0,2 : +1 faux détecté mais 3 vrais accusés à tort → seuil maintenu à 0,5

L'application : un fichier ou un billet, une réponse

Script : Rizki_Sabah_2_Script_application_102026.py

- Charge le pipeline sauvegardé (imputation + standardisation + régression logistique)
- Entrée : un CSV (séparateur , ou ; détecté) ou les 6 valeurs d'un billet
- Sortie binaire (1 = faux) + probabilité + alerte de contrôle
- Robuste : contrôle des colonnes, mesure manquante complétée, export CSV

```
> python Rizki_Sabah_2_Script_application_102026.py
      --csv billets_production.csv

 id   prediction resultat proba_faux controle
 A_1           1     FAUX     0.9989
 A_2           1     FAUX     0.9999
 A_3           1     FAUX     0.9997
 A_4           0     VRAI     0.0206
 A_5           0     VRAI     0.0001

Bilan : 5 billet(s) analysé(s)
        -> 3 FAUX, 2 VRAI(S).
```

Un détecteur fiable, explicable et prêt à l'emploi

Régression logistique : 98,9 % de bonnes réponses, 96,8 % des faux détectés, aucune fausse alerte sur le test

Prochaines étapes

Tester sur les billets réels du quotidien et suivre la performance dans le temps

Données

Enrichir avec des faux billets récents : les faussaires évoluent

Pistes

Ajuster le seuil avec vous selon le coût réel d'un faux ; tester SVM ou gradient boosting