L a p a g e

Analyse de l'activité en ligne

Méthode · Indicateurs · Tests statistiques · Recommandations

Data Analyst — Équipe Marketing · CODIR

Chiffres clés — Vue d'ensemble

Après nettoyage des données · Mars 2021 – Février 2023

~11,8 M€ CA total (après nettoyage)	**8 600** Clients actifs	**342 015** Commandes valides
~493 K€ CA moyen / mois	**3 265** Références actives	**34,63 €** Panier moyen / commande (AOV)

Données nettoyées : 200 lignes test_ supprimées · 827 doublons session+produit retirés · 221 id_prod orphelins exclus

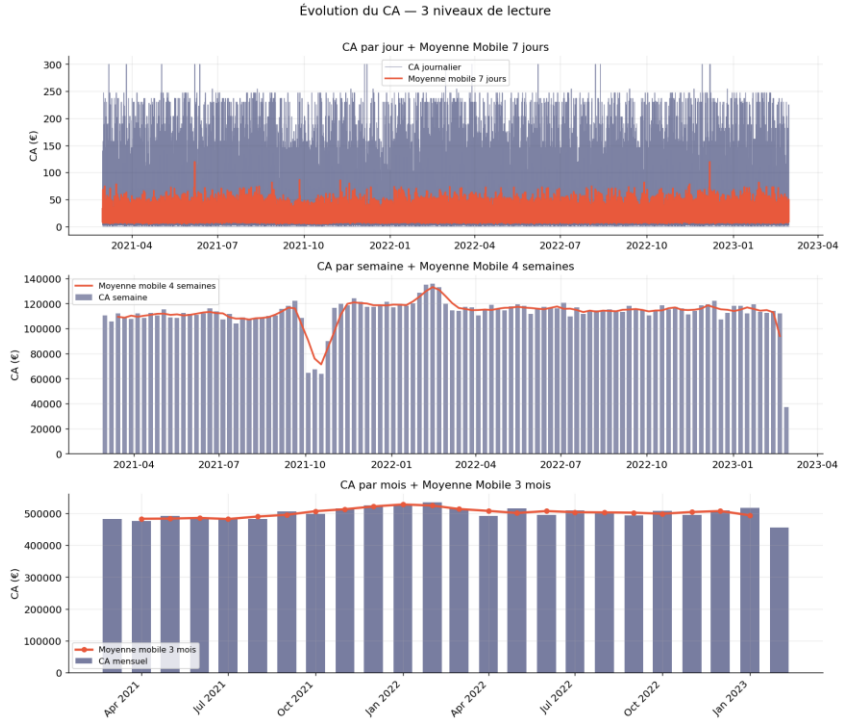
Méthodologie — Données & Nettoyage

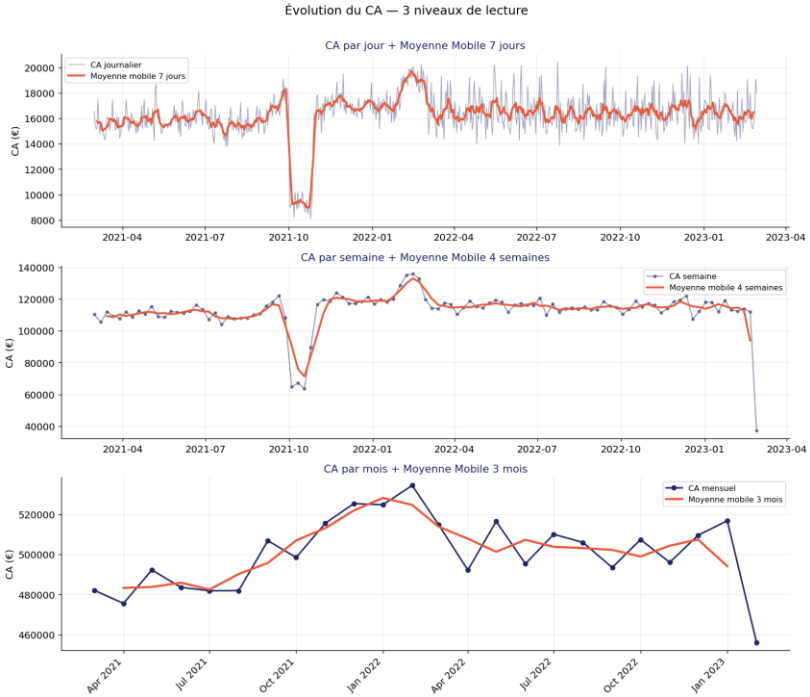
Traçabilité complète des décisions de nettoyage et des remplacements de données manquantes

Anomalie	Volume	Impact CA	Décision motivée
Lignes test_ (date invalide)	200 lignes	Nul (date invalide)	Suppression — données inutilisables
Doublons session+produit	827 lignes	Surévaluation CA	Garder 1ère occurrence — double-clic détecté
Réf. 0_2245 hors catalogue	221 lignes	~50% vol. orphelin	Imputation — prix médian cat. 0 (10,32€)
Clients sans achat	23 clients	Nul	Conservation — statut inactif documenté
Clients BtoB (tests seuls)	4 clients	7,4% CA	Exclusion des tests comportementaux uniquement
Prix négatif (T_0 = −1€)	1 référence	Nul (1 réf.)	Prix → NaN → exclu au calcul du CA
Trou de données oct. 2021	~50% du volume	CA sous-évalué	Imputation — régression linéaire (×1,56)

Évolution du CA — 3 niveaux de lecture

Le CA analysé à 3 échelles (jour, semaine, mois), chacune avec sa moyenne mobile pour lisser les fluctuations.

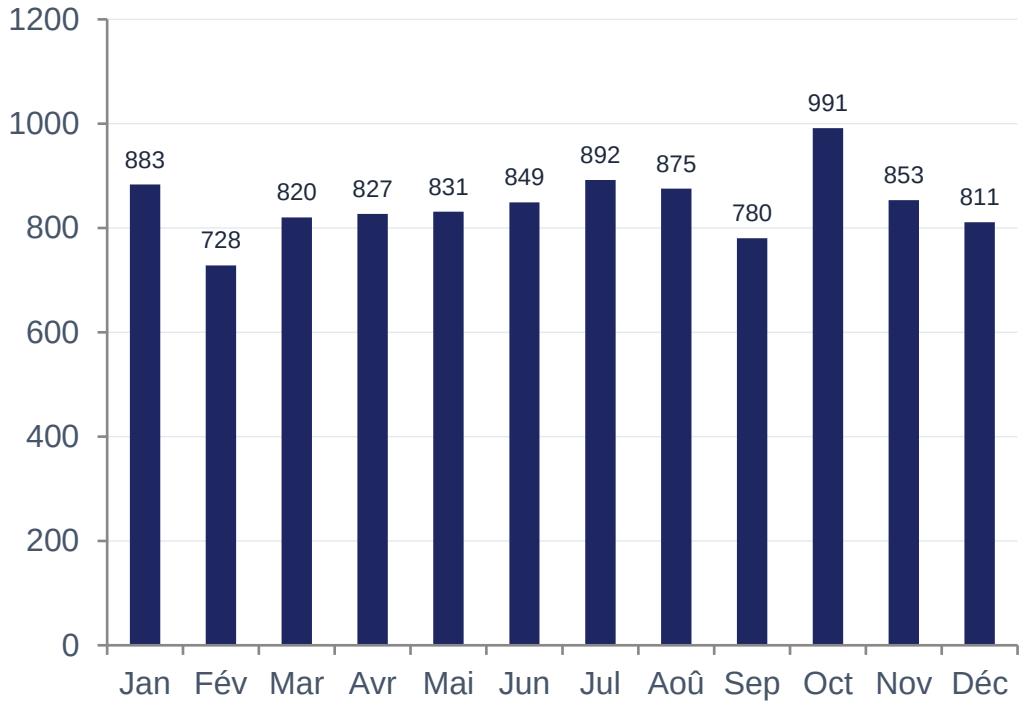




Lecture & choix : 3 échelles pour révéler la tendance sous le bruit quotidien. Moyennes mobiles (7j/4sem/3mois) pour lisser. Octobre 2021 (trou de données) imputé par régression linéaire. → CA en hausse en 2021 puis plateau à ~493 K€/mois en 2022 : l'activité a atteint sa vitesse de croisière.

Saisonnalité — Comparaison mensuelle

CA agrégé sur 2 ans · Identification des mois forts et faibles



—

Pas de saisonnalité forte détectée

Oct 21

Trou de données (exclu)

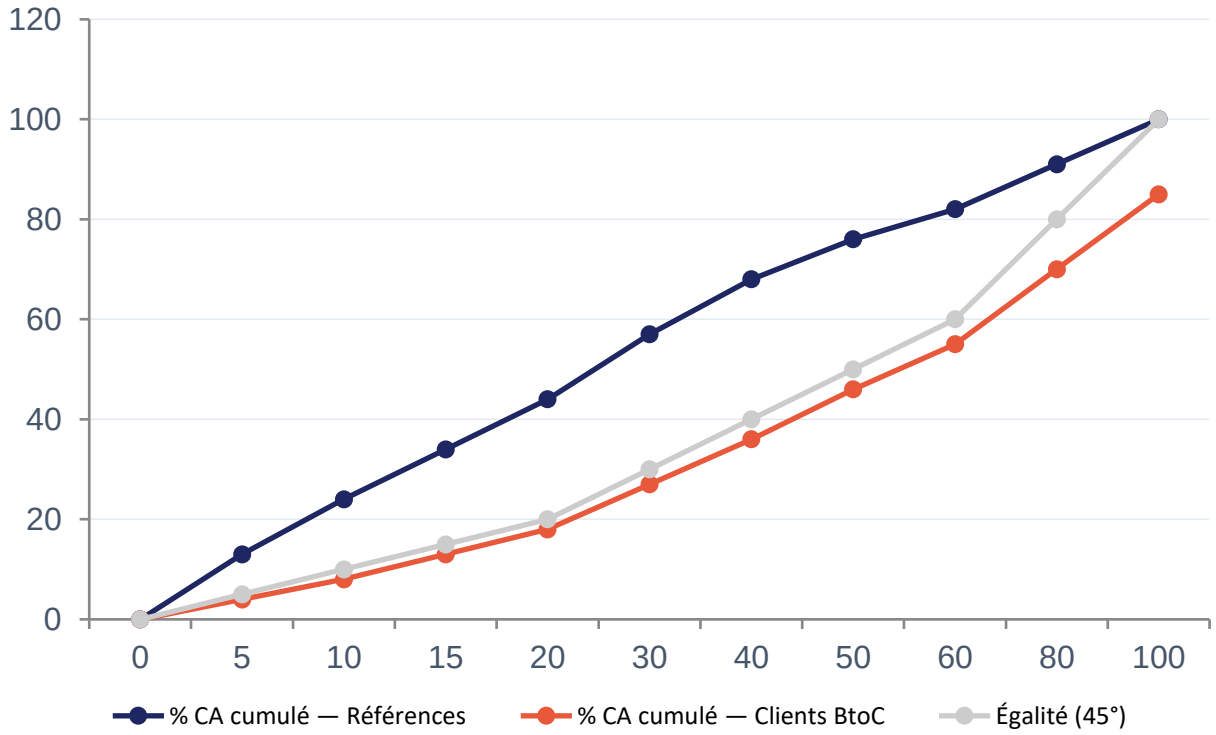
Profil saisonnier

Aucun mois ne se détache nettement (Oct 2021 exclu)

Pas de saisonnalité exploitable sur ce dataset · Investiguer la cause du trou de données d'octobre 2021

Effet Pareto — Concentration du CA

Loi 80/20 sur les références produits et les clients BtoC



21,5 %
des références
→ 80% du CA
(702 réf. / 3 265)

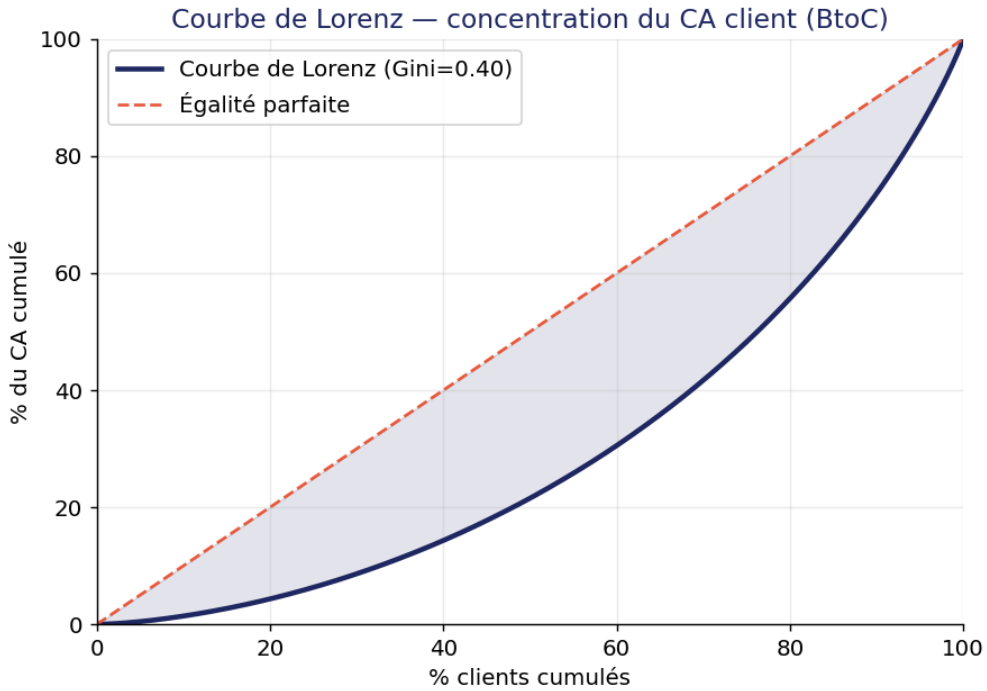
Gini
= 0,40
Concentration
modérée (clients)

52 %
des clients BtoC
→ 80% du CA
(moins 80/20)

Références : effet Pareto fort (21% → 80% CA) · Clients : concentration modérée → programme fidélité VIP prioritaire

Courbe de Lorenz — concentration clients

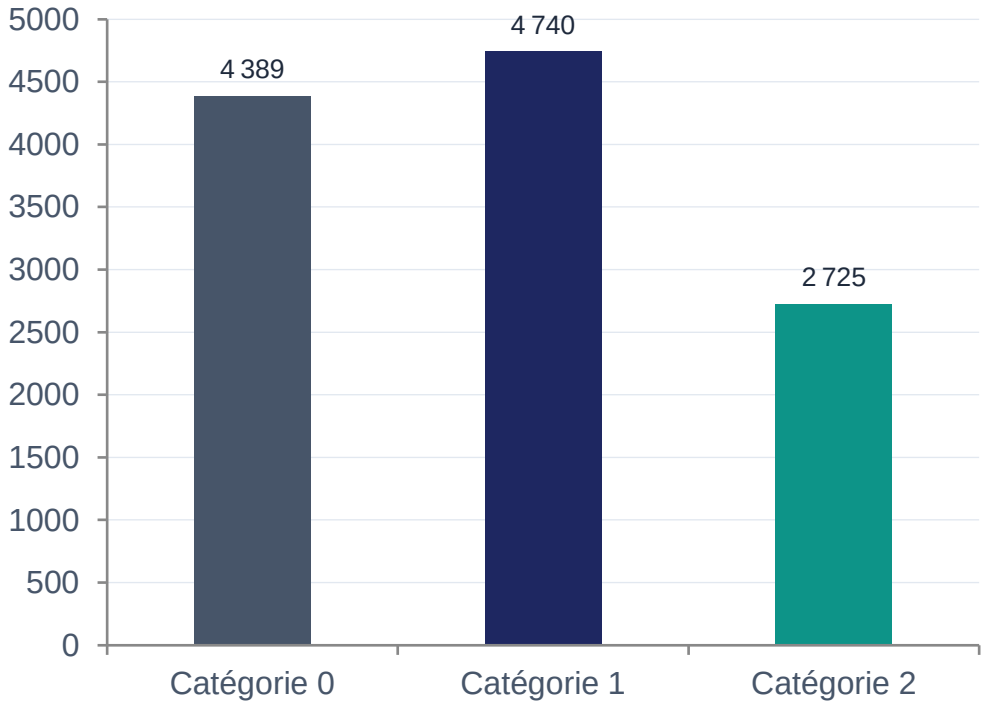
La courbe de Lorenz mesure l'inégalité de répartition du CA entre les clients (indice de Gini).



Conclusion : Gini = 0,40 : concentration modérée mais réelle. Une minorité de clients génère une part importante du CA — d'où l'intérêt d'un programme de fidélité ciblé sur les meilleurs clients.

Analyse des ventes — Catégories & Références

CA total sur 2 ans



40%

Catégorie 1
(produits haute valeur)

37%

Catégorie 0
(références larges)

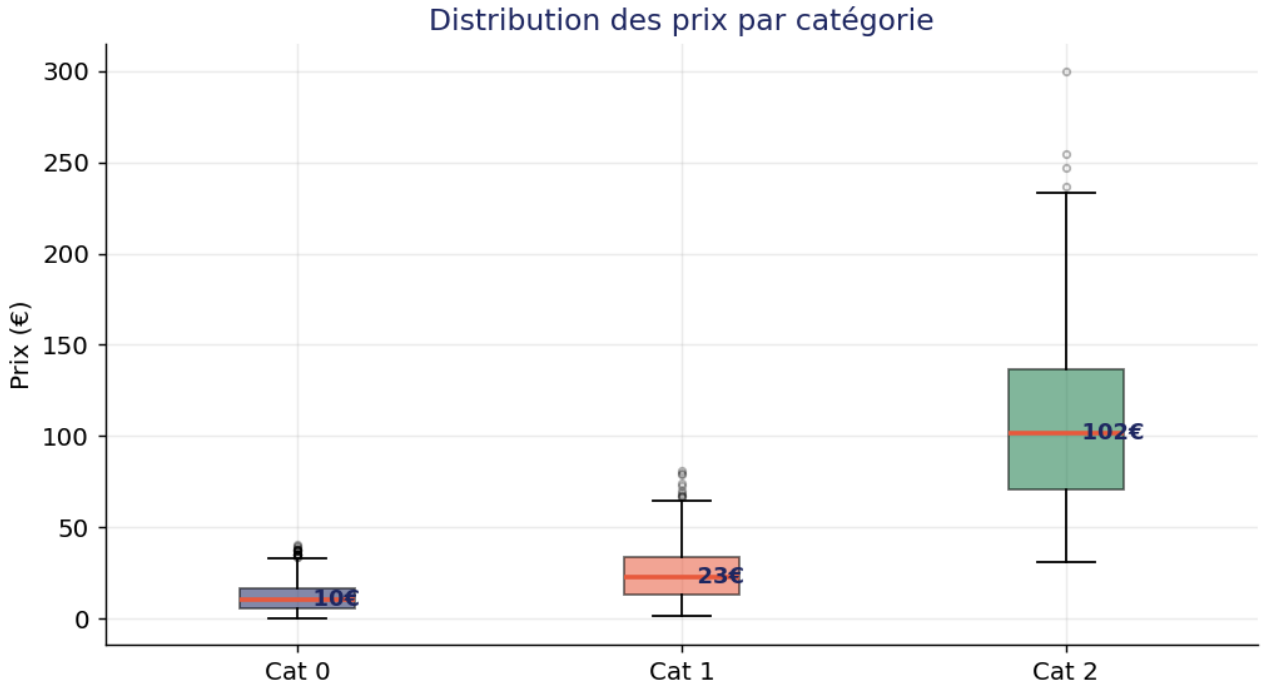
23%

Catégorie 2
(niche jeunes)

Références fantômes : vendues 1× en 2 ans → rationalisation catalogue sans impact CA

Prix par catégorie de produit

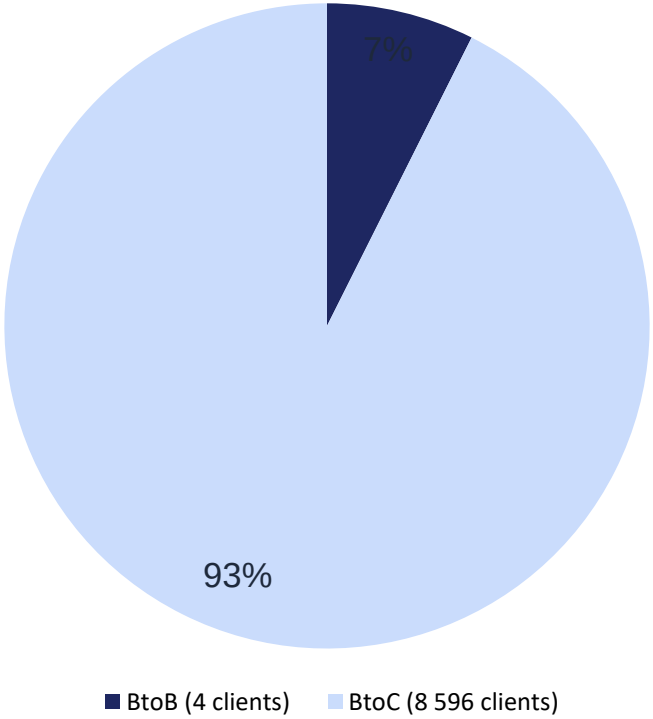
Distribution des prix (boxplot) pour chacune des 3 catégories de la librairie.



Conclusion : Les 3 catégories forment 3 gammes de prix distinctes : Cat 0 ~10€ (entrée de gamme), Cat 1 ~23€ (milieu), Cat 2 ~102€ (haut de gamme). La catégorie structure fortement le prix.

Profil clients — BtoB vs BtoC

4 clients atypiques identifiés par rupture statistique



Client	CA 2 ans
c_1609	324 033 €
c_4958	289 760 €
c_6714	153 599 €
c_3454	113 638 €
Total BtoB	**881 031 €**

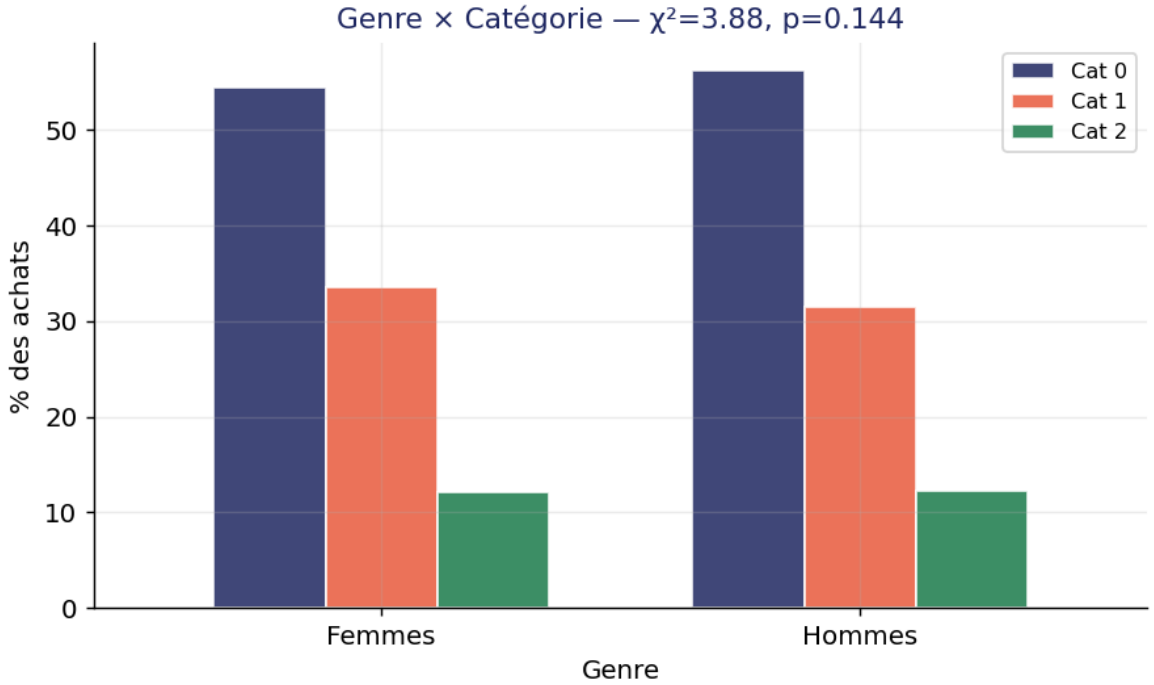
Rupture statistique

5ème client : 5 277 € — soit 22× moins que c_3454. Signal sans ambiguïté.

Segment BtoB = 7,4% du CA sans stratégie dédiée → opportunité non exploitée · Seuil robuste : conclusions identiques avec 4, 5 ou 6 clients exclus

Test 1 — Genre × Catégorie

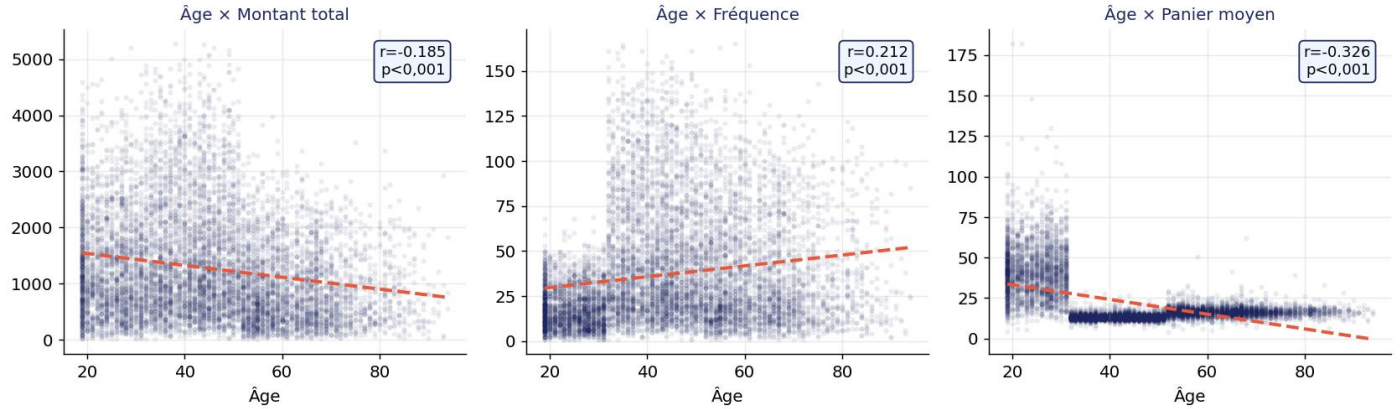
On teste si le genre du client influence la catégorie de livres achetée (Chi-2, 2 variables qualitatives).



Conclusion : p = 0,138 > 0,05 → pas de lien significatif. Hommes et femmes achètent dans les mêmes proportions. Inutile de segmenter le marketing par genre.

Tests 2-3-4 — Âge × Comportement d'achat

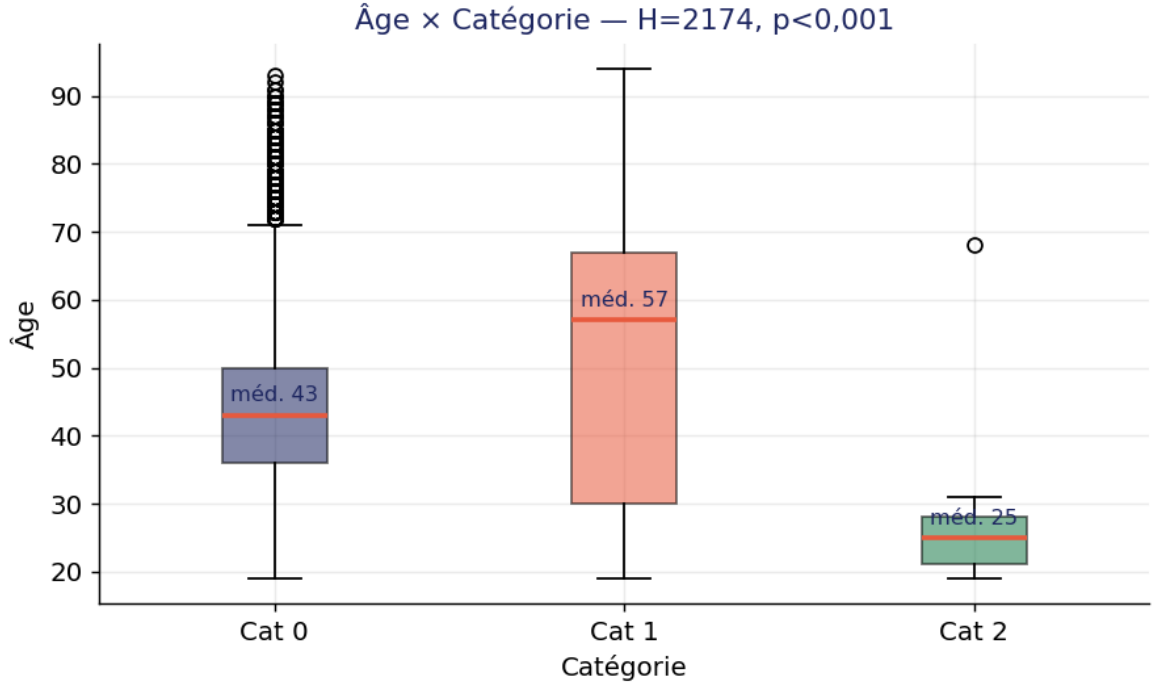
On teste le lien entre l'âge et 3 comportements : montant total, fréquence, panier moyen (Spearman, normalité non vérifiée).



Conclusion : Les 3 liens sont significatifs (p<0,001) mais d'effet modéré (r^2 de 3 à 11%). Les clients jeunes dépensent plus au total et ont des paniers plus élevés ; les clients plus âgés achètent plus fréquemment.

Test 5 — Âge × Catégorie

On teste si les 3 catégories ont des profils d'âge différents. Après Shapiro-Wilk (normalité non vérifiée) ET Levene (variances inégales, p<0,001), on retient Kruskal-Wallis plutôt que l'ANOVA.



Conclusion : H=2175, p<0,001 → lien très fort. Cat 2 = jeunes (~25 ans), Cat 0 = ~43 ans, Cat 1 = seniors (~57 ans). Base de segmentation par âge.

Synthèse — Récapitulatif des 5 tests

Scope : BtoC uniquement · Référence XLSTAT · α = 0,05

Corrélation	Tableau / données	Test retenu	Statistique	p-value	Conclusion
Genre ↔ Catégorie	Tableau de contingence (2×3)	Chi-2 (χ^2)	χ^2=3,97 ddl=2	0,138	**Pas de lien ✗**
Âge ↔ Montant	Desc. par tranche d'âge	Spearman*	r = −0,185	< 0,001	**Lien négatif ✓**
Âge ↔ Fréquence	Desc. par tranche d'âge	Spearman*	r = +0,212	< 0,001	**Lien positif ✓**
Âge ↔ Panier moyen	Desc. par tranche d'âge	Spearman*	r=−0,326 (r^2=11%)	< 0,001	**Lien modéré ✓**
Âge ↔ Catégorie	Médiane âge par catégorie	Kruskal-Wallis**	H = 2174,51	< 0,001	**Lien très fort ✓**

**Spearman = équivalent non param. de Pearson · **ANOVA → Kruskal-Wallis (cond. 4 non vérifiée) · Panier = prix moyen/article (~17€), pas l'AOV/commande (~34€)*

Insight clé : l'âge est le meilleur prédicteur disponible (effet modéré, 3 à 11% de variance) · Jeunes < 30 ans → Catégorie 2 · Seniors 50+ → Catégorie 1 · À combiner avec d'autres données pour affiner

Recommandations stratégiques

4 actions prioritaires — décision CODIR

01

Programme fidélité VIP

21% des références = 80% CA · Fidéliser les clients les plus actifs : accès anticipé, remises, invitations.

02

Campagnes segmentées par âge

Données disponibles maintenant : < 30 ans → Cat 2 · 50+ → Cat 1 · Activation emails immédiate.

03

Rationaliser le catalogue

Dizaines de références vendues 1× en 2 ans → supprimer. Zéro impact CA, gain logistique direct.

04

Structurer une offre BtoB

Structurer une offre commerciale dédiée pour les 4 clients BtoB qui pèsent 7,4% du CA sans stratégie actuelle.

E n s y n t h è s e

01 Activité saine & stable

CA mensuel ~493 K€ · 8 600 clients · tendance haussière 2021 puis plateau.

02 Pareto fort sur les références

21% des références = 80% CA · Concentration modérée des clients (Gini 0,40).

03 L'âge : variable clé

Segmentation produit ET comportement · Les jeunes sont les meilleurs clients.

Merci de votre attention