OPENCLASSROOMS

Analyse Sociodémographique des Étudiants Data

Évolution des profils 2022 – 2025

Pipeline DBT · Snowflake · Enrichissement INSEE

Mai 2025 — Sabah Rizki, Data Analyst

01 · Contexte & Objectifs

Contexte

OpenClassrooms souhaite objectiver l'évolution du profil de ses étudiants Data sur 4 ans.

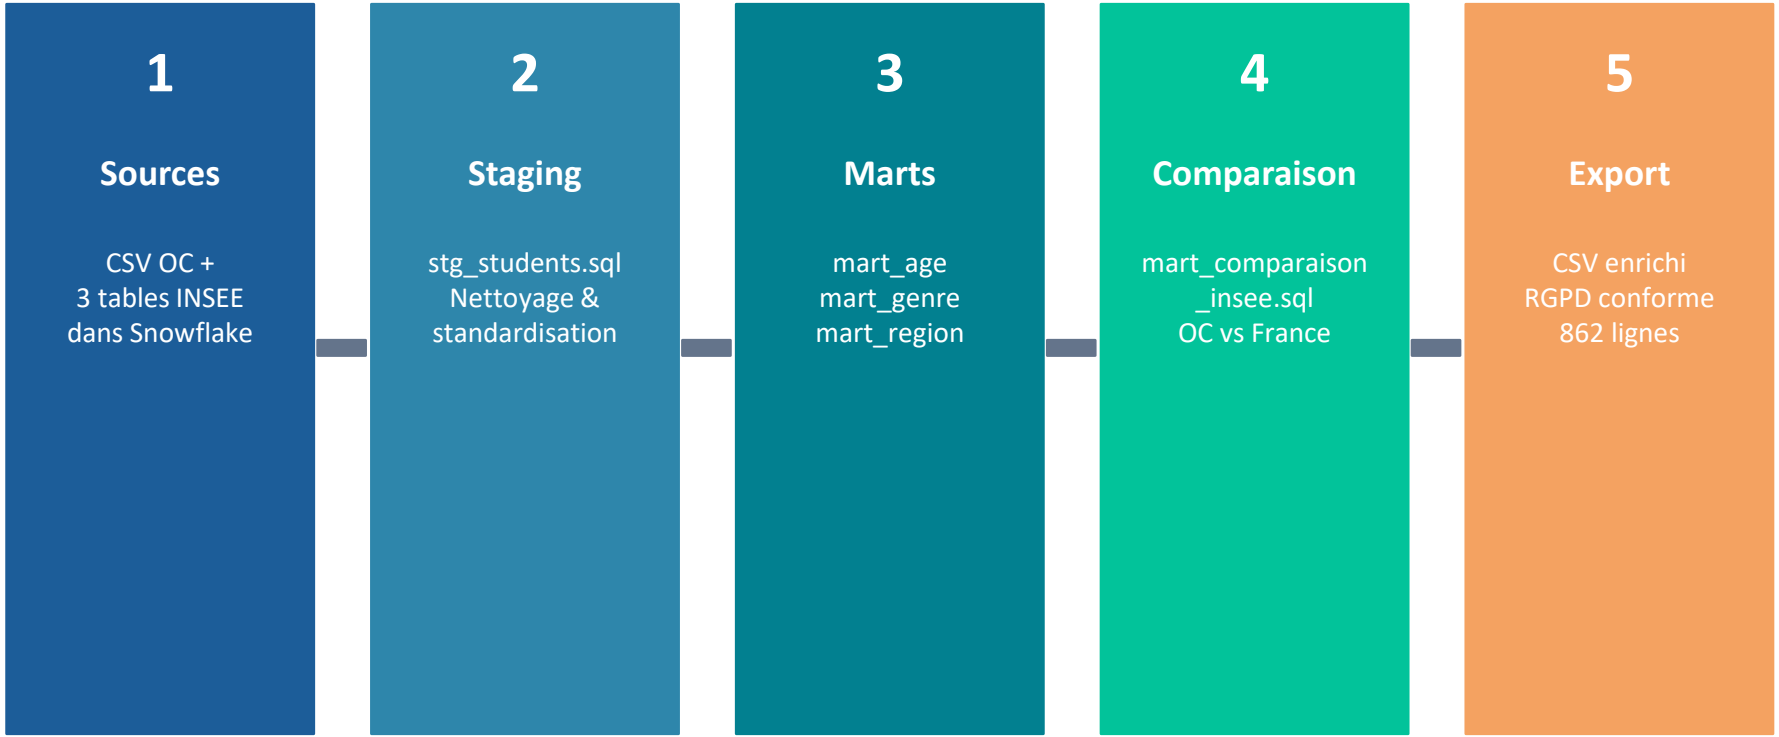
Trois dimensions analysées :

- Répartition par tranche d'âge
- Répartition par genre
- Répartition géographique par région

Objectifs

- Préparer & fiabiliser les données internes via DBT
- Vérifier la conformité RGPD des traitements
- Enrichir avec 3 sources publiques INSEE
- Produire des indicateurs exploitables par la direction pédagogique

02 · Architecture Technique



03 · Conformité RGPD

Minimisation

Seules les variables utiles sont conservées : AGE_GROUP, GENDER, REGION, YEAR_PATH_STARTED. Le USER_ID est exclu du CSV final exporté.

Pseudonymisation

L'identifiant USER_ID est pseudonymisé. Conservé uniquement en interne pour les jointures, jamais exposé dans les livrables.

Agrégation

Le CSV final contient uniquement des données agrégées par groupe (COUNT). Aucune donnée individuelle n'est exposée.

Données publiques

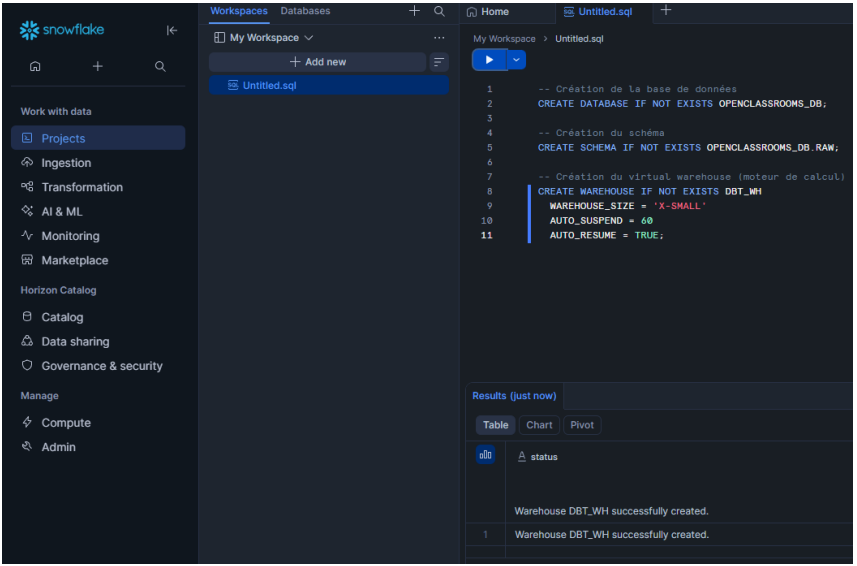
Les 3 sources INSEE (âge, genre, région) sont librement accessibles sur insee.fr. Aucune donnée personnelle.

04 · LES ÉTAPES DU PROJET

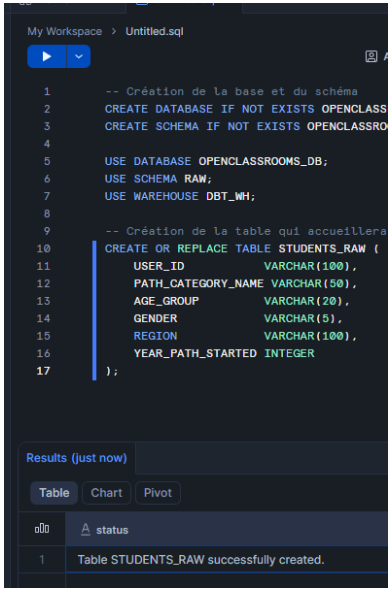
Mise en place : Création de la base Snowflake

PHASE 1	PHASE 2	PHASE 3	PHASE 4
Snowflake — Stocker	DBT — Transformer	Tester — Vérifier	Livrer — Exporter

Création de la database, du schéma et du warehouse via SQL :

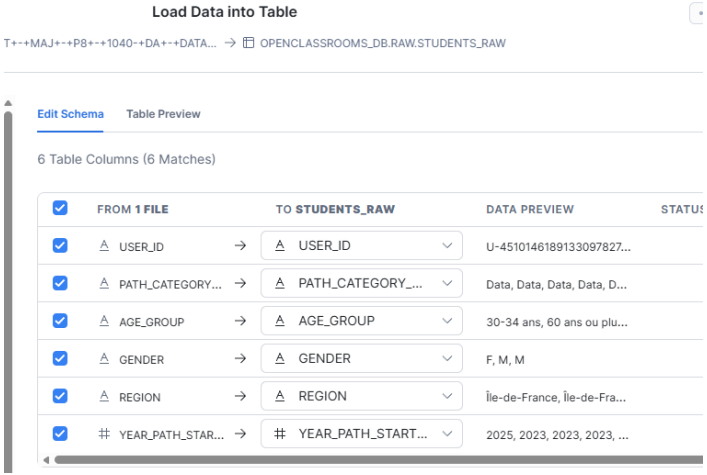


Création de la table STUDENTS_RAW (6 colonnes) :

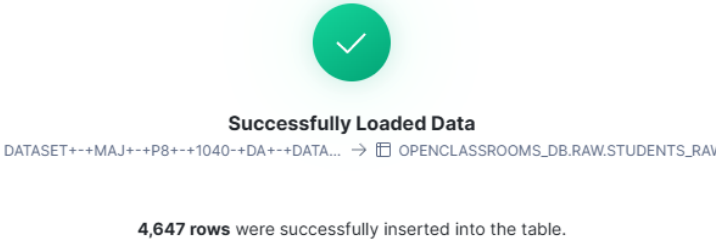


04 · Mise en place : Import des données dans Snowflake

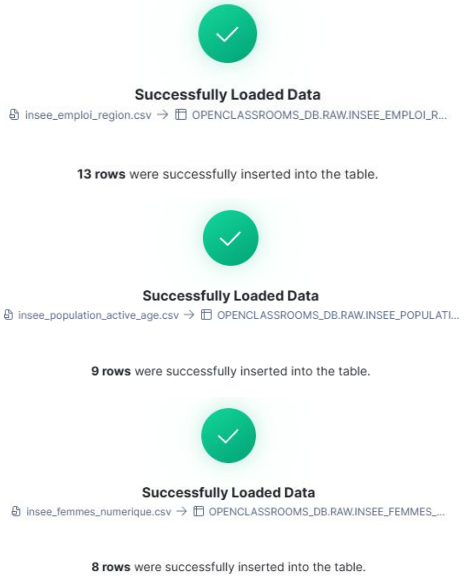
Étape 1 — Mapping des colonnes CSV → Table STUDENTS_RAW :



Résultat — 4 647 lignes chargées avec succès ☑ :



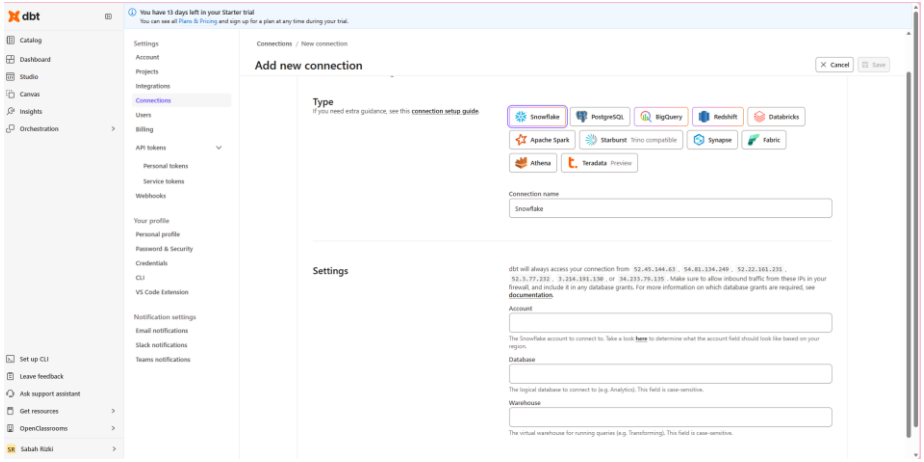
Import des 3 sources INSEE :

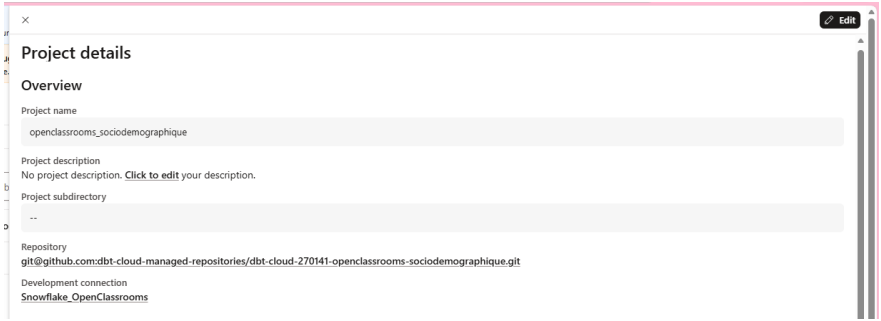


INSEE âge : 9 lignes ☑
INSEE femmes : 8 lignes ☑
INSEE région : 13 lignes ☑

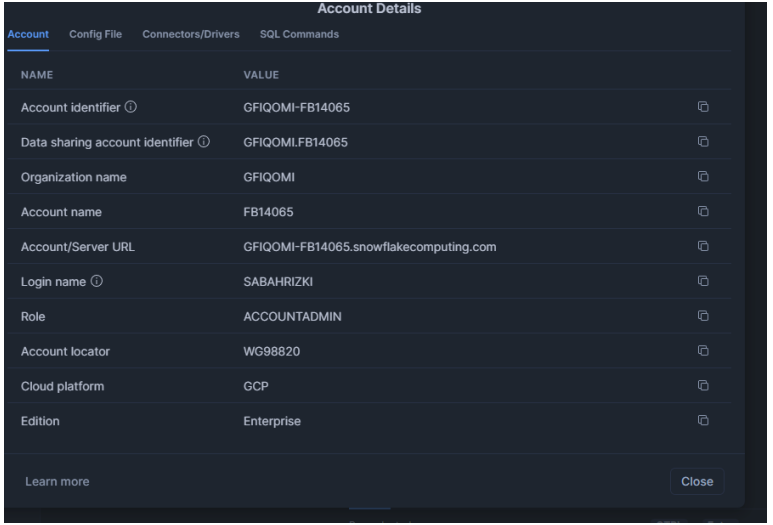
04 · Mise en place : Configuration DBT Cloud

Connexion DBT ↔ Snowflake (account, database, warehouse) :



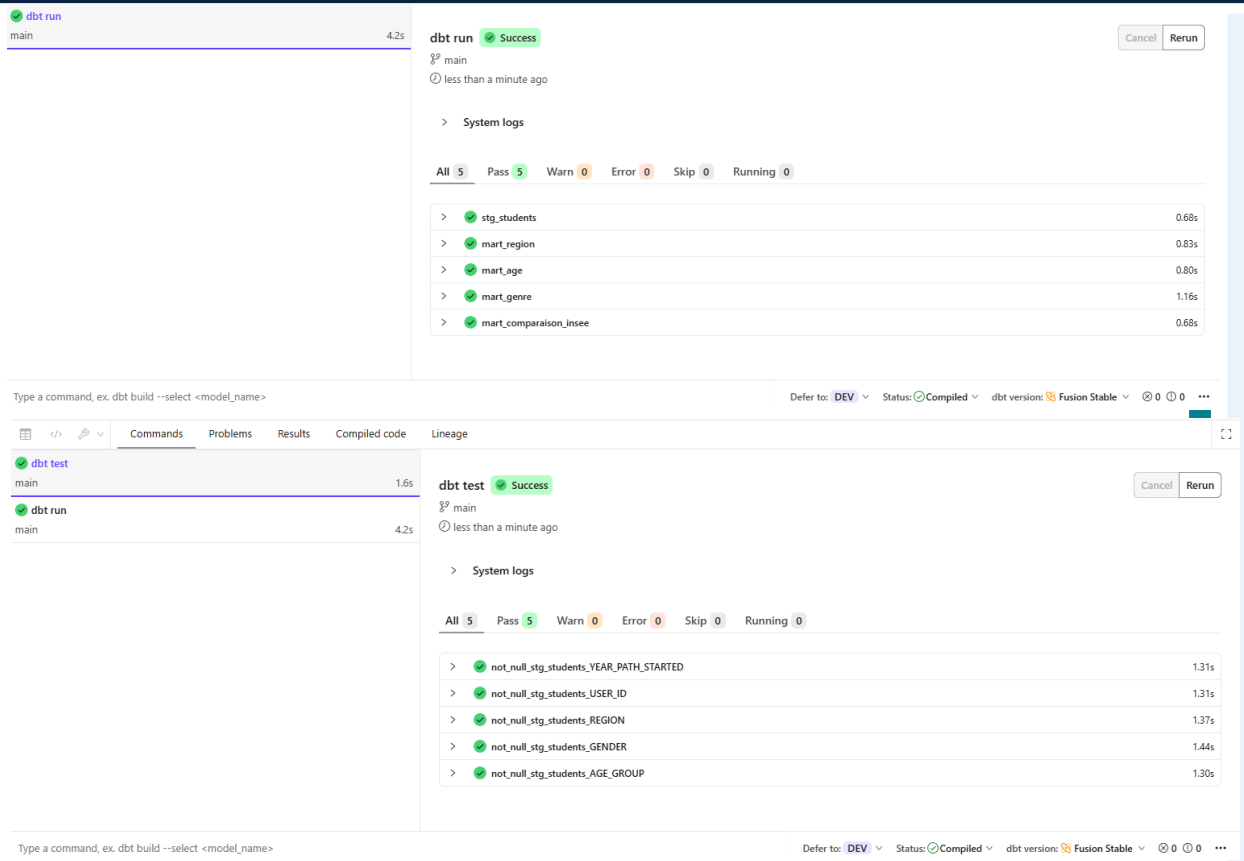


Paramètres de connexion



Projet DBT configuré et opérationnel :

05 · Pipeline DBT & Tests qualité



Modèles créés

sources.yml

4 sources Snowflake déclarées

stg_students.sql

Nettoyage + coalesce()

mart_age.sql

Agrégation par âge

mart_genre.sql

Agrégation par genre

mart_region.sql

Agrégation par région

mart_comparaison_insee

Jointure OC ↔ INSEE

Tests automatisés :

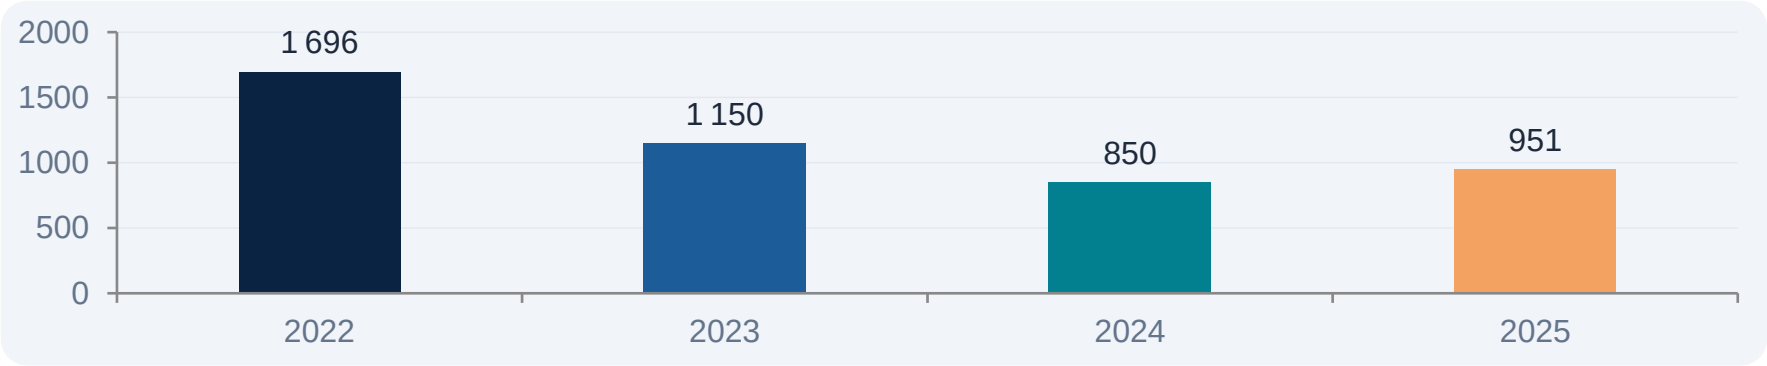
06 · Vue d'ensemble : 4 647 étudiants sur 4 ans

4 647
étudiants
au total

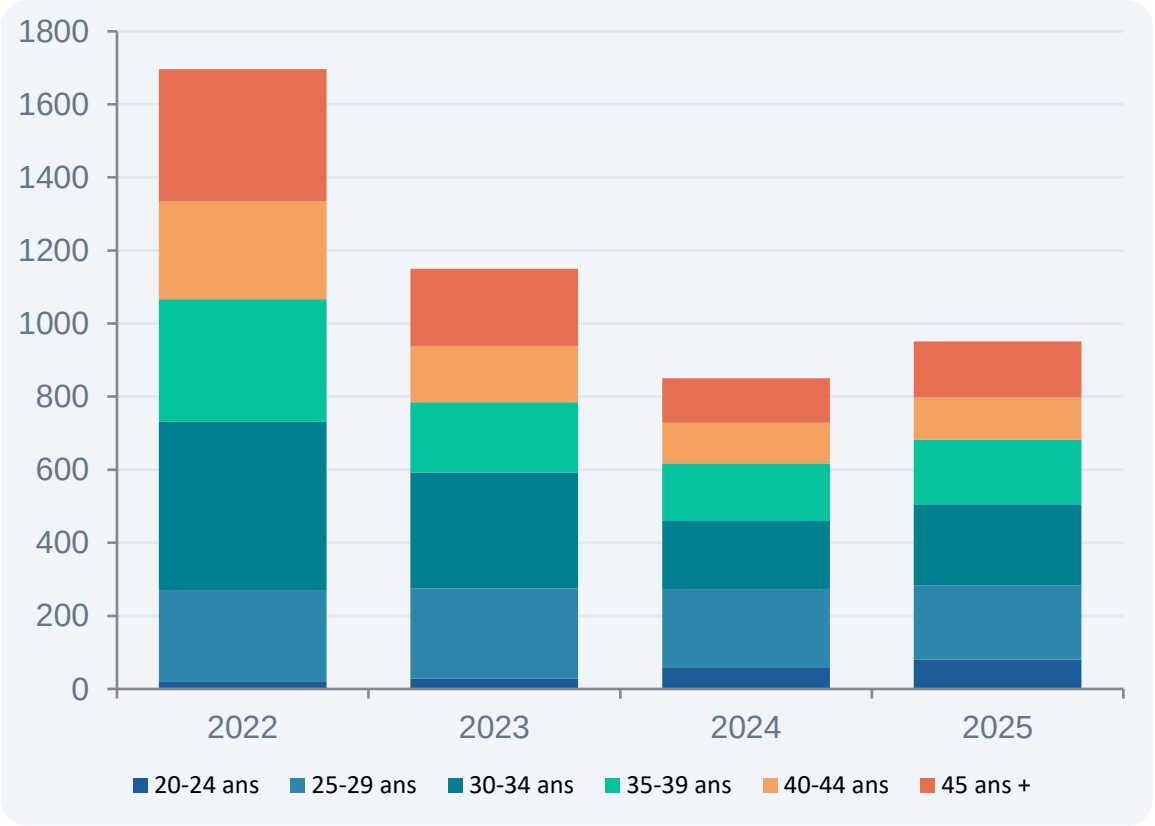
1 696
inscrits
en 2022 (pic)

850
inscrits
en 2024 (creux)

951
inscrits
en 2025 (reprise)



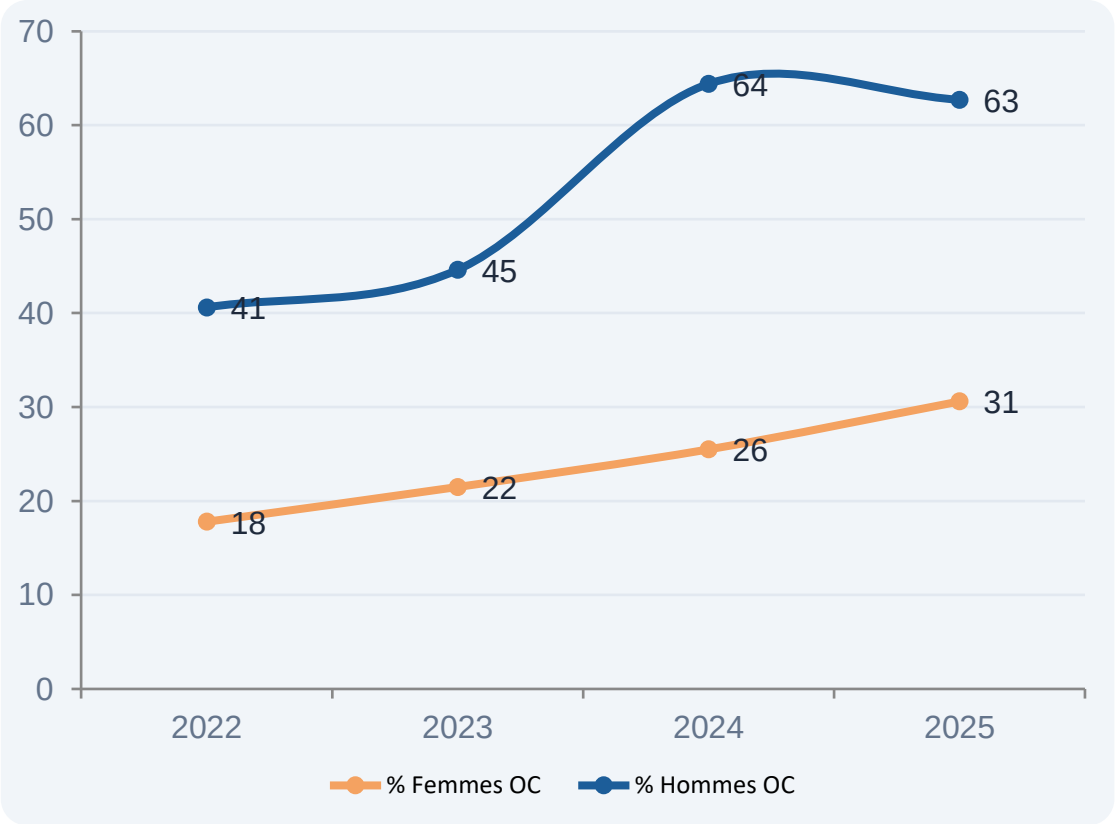
07 · Évolution par tranche d'âge



Points clés

- 30-34 ans : tranche dominante chaque année
- 20-24 ans × 4 en 4 ans : 21 → 81 (+286%)
- 45 ans+ : recul 361 → 172 (-52%)
- Rajeunissement progressif du profil

08 · Évolution par genre

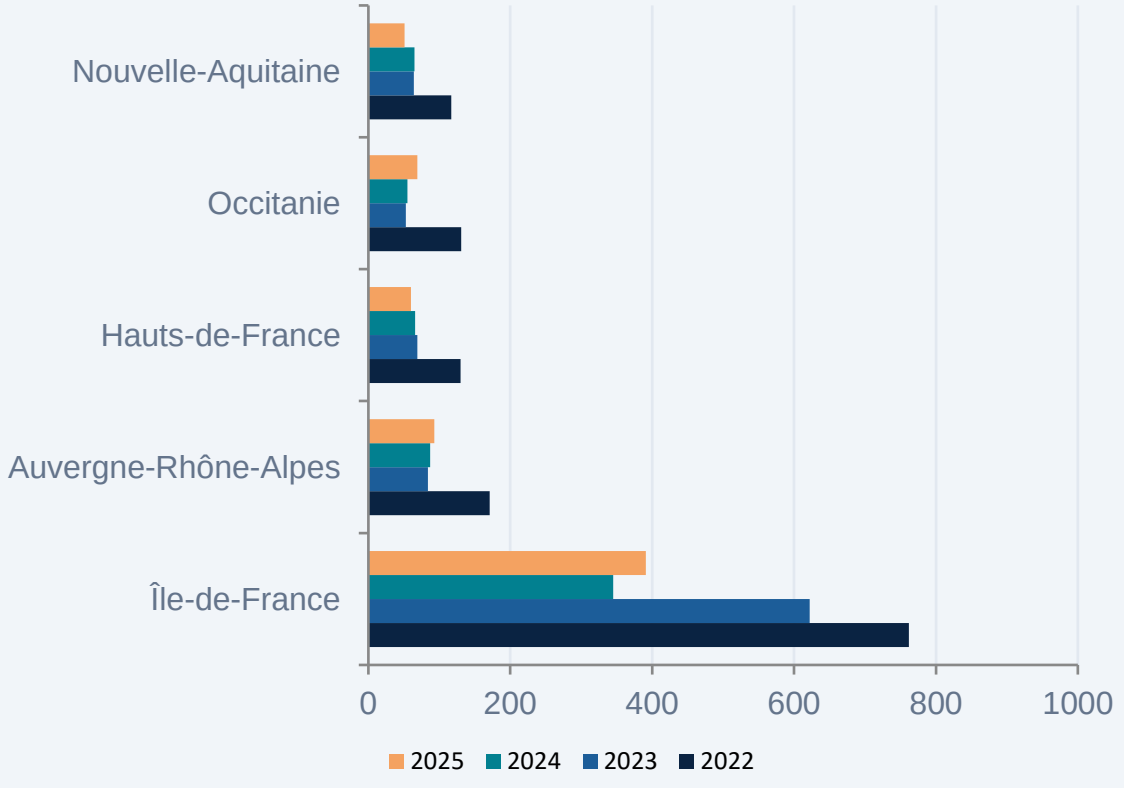


Répartition détaillée

Année	F	M	NR
2022	302 (18%)	688 (41%)	706 (42%)
2023	247 (21%)	513 (45%)	390 (34%)
2024	217 (26%)	547 (64%)	86 (10%)
2025	291 (31%)	596 (63%)	64 (7%)

NR = genre non renseigné
Taux NR : 42% → 7% en 4 ans
→ meilleure fiabilité des données

09 · Évolution par région

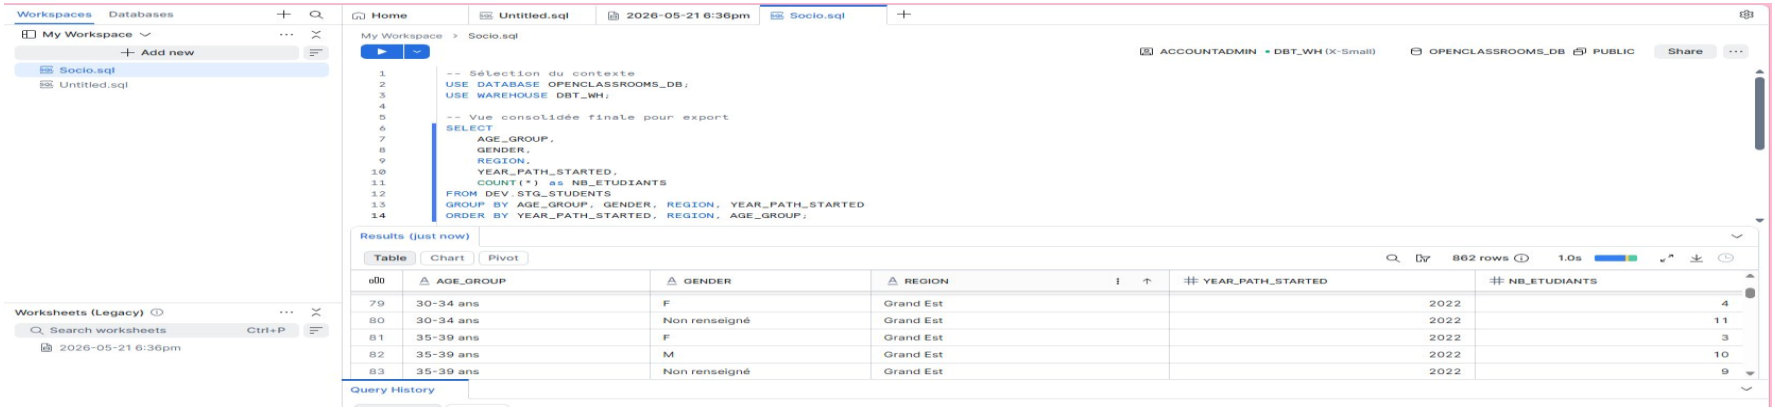


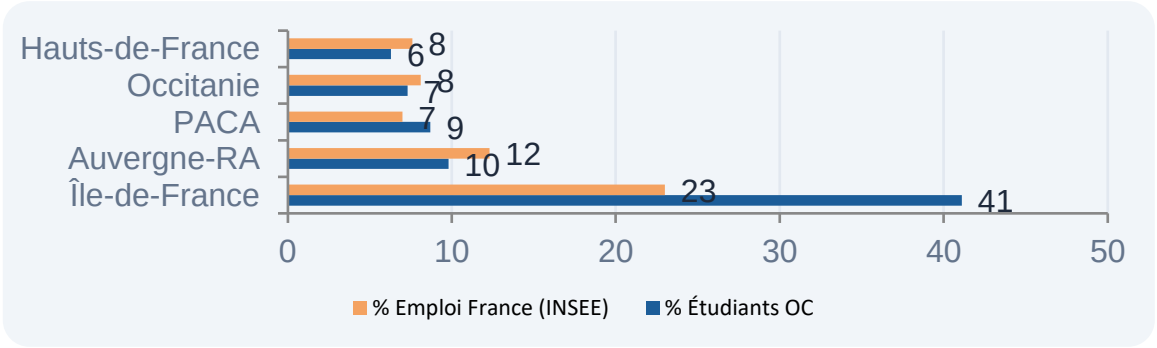
Points clés

- Île-de-France : 1ère région chaque année (41-54%)
- Auvergne-Rhône-Alpes : 2ème place stable (~10%)
- PACA : 3ème position en 2025 (8.7%)
- DROM : faible représentation (1.7%)

10 · Comparaison OC vs données INSEE

Export final enrichi INSEE — 862 lignes (écarts région calculés sur 2025) :





Écarts clés OC vs INSEE

IDF sur-représentée	+18.1 pts
Femmes OC vs num. INSEE	+6.6 pts
Nouvelle-Aquitaine	-3.2 pts
DROM	-1.3 pts

11 · Synthèse & Recommandations

4 tendances identifiées

- Baisse des inscriptions –44% (2022→2024), reprise +12% en 2025
- Rajeunissement : 20-24 ans ×4 en 4 ans (+286%)
- Féminisation : 18% → 31% de femmes, dépasse la moyenne INSEE (24%)
- Concentration IDF : +18 pts vs emploi national (INSEE)

4 recommandations stratégiques

R1	Analyser les causes du recul des inscriptions 2022→2024
R2	Adapter l'offre pédagogique au profil plus jeune (20-24 ans)
R3	Capitaliser sur la féminisation, viser 35% en 2027
R4	Cibler Nouvelle-Aquitaine, PDL et DROM avec actions locales

CONCLUSION

Un pipeline fiable pour des décisions éclairées

✓

Fichier CSV enrichi

862 lignes · données OC
+ comparaison INSEE · RGPD ☑

✓

Pipeline DBT

4 sources · 5 modèles
testé · documenté · reproductible

✓

Cette présentation

15 slides · étapes documentées
captures d'écran · recommandations

Merci pour votre attention — Questions ?