OpenClassrooms · Parcours Data Analyst · Projet 13

Pilotez un projet data augmenté avec l'IA

Documentation de la démarche : amélioration du notebook BottleNeck (P6)

Livrable 2 · Veille, cahier des charges, gestion de projet, essais IA, formation, limites et décisions

Sabah Rizki
Data Analyst · 20 ans d'expérience Supply Chain
Version du 21 octobre 2026

Sommaire

1. Synthèse 3
2. Veille métier et technologique 4
  2.1 Besoin identifié 4
  2.2 Système de veille 4
  2.3 Comparatif des solutions de contrôle des données 5
  2.4 Méthodes d'analyse retenues 6
  2.5 Pistes d'amélioration continue 6
3. Cahier des charges fonctionnel 7
  3.1 Contexte et parties prenantes 7
  3.2 État actuel 7
  3.3 Problématique reformulée 7
  3.4 Objectifs, enjeux et priorités 7
  3.5 Périmètre 8
  3.6 Contraintes 8
  3.7 Spécificités fonctionnelles 8
  3.8 Ressources et budget 8
  3.9 Livrables et planning 9
  3.10 Critères de réussite et d'acceptation 9
4. Organisation et pilotage du projet 10
  4.1 Découpage en lots et backlog 10
  4.2 Points de contrôle et versioning 10
  4.3 Registre des risques 10
5. POC : amélioration du P6 avec l'IA 12
  5.1 Hypothèses 12
  5.2 Protocole 12
  5.3 Résultats 12
  5.4 Constats qualitatifs 13
  5.5 Décisions : ce qui est gardé, ce qui est écarté 13
  5.6 Ce que change le notebook amélioré 13
6. Mini-plan de formation 14
  6.1 Accessibilité des supports et des séances 14
  6.2 Indicateurs de réussite 14
7. Limites, biais et risques résiduels 15
8. Reproductibilité 16
9. Synthèse pour le client 17
Annexes 18
  A. Journal des essais IA 18
  B. Prompts 18
  C. Référentiel des anomalies 18
  D. Règles de notation 19
  E. Glossaire 19

1. Synthèse

Le besoin. BottleNeck, caviste en ligne, prépare la migration vers un nouvel ERP. Son analyse de stock et de ventes (projet P6) reposait sur des contrôles écrits à la main, des chiffres saisis en dur et des hypothèses implicites : elle ne pouvait pas être rejouée à chaque export, et certains de ses constats étaient faux.

La démarche. Une veille ciblée, un cahier des charges, puis un test comparatif de deux IA (Claude et Gemini, 2 prompts, 6 essais) évalué sur un banc de test automatique, et enfin une comparaison mesurée de trois façons de contrôler les données (pandas seul, Pandera, Great Expectations). Le projet est piloté dans Airtable (25 tâches, 8 jalons, 12 risques).

Les résultats.

- **Essai retenu : C-P2 (Claude, prompt enrichi), 91,9/100.** Le contexte métier dans le prompt compte plus que le choix de l'outil : il rapporte 10 points à Claude et 69 à Gemini, alors qu'à prompt égal les deux outils ne sont séparés que de 8,4 points.
- **Le notebook amélioré contrôle automatiquement les données** avec 64 règles Pandera (325 anomalies signalées, chacune classée BLOQUANT ou ALERTE) et produit un rapport Excel à chaque exécution. Il tourne en 8 secondes, avec des sorties identiques sous pandas 2 et 3.
- **Quatre erreurs du P6 corrigées**, dont une conclusion renversée : le stock est bien lié aux ventes (Spearman 0,76, contre 0,44 en Pearson).
- **Un enjeu de trésorerie mis au jour** : sous l'hypothèse du P6, 79,5 % de la valeur du stock (220 378 €) couvre plus de 24 mois de ventes, et 65 produits hors vente immobilisent 21 403 €.

> **Décision.** Brancher le module de contrôle en entrée de la migration ERP (aucun chargement tant qu'il reste une ligne BLOQUANT), lancer un plan de déstockage chiffré, et faire préciser par BottleNeck la période couverte par les ventes, dont dépendent toutes les couvertures de stock.

2. Veille métier et technologique

2.1 Besoin identifié

L'audit du P6 (réexécution complète et vérification par script de chaque chiffre) a fait ressortir un besoin précis : **fiabiliser le contrôle qualité des données et le rendre rejouable**. Le récapitulatif du P6 annonçait 4 ventes à perte alors que son code en trouvait 7, un contrôle de jointure comparait deux clés différentes, et le classement des ventes changeait selon la version de pandas. La veille porte donc sur trois questions : quels outils pour valider des données en Python, comment utiliser l'IA sans risque pour écrire ces contrôles, et quelles méthodes d'analyse corrigent les biais du P6.

2.2 Système de veille

Critères de sélection d'une source : source primaire (documentation officielle, autorité publique, publication évaluée par des pairs), datée de moins de 24 mois ou version en cours, directement utile à une décision du projet. Chaque source a été ouverte et lue le 21/10/2026.

Thème	Source	Date / version	Ce qu'on en retient
Outil	Pandera, page PyPI	v0.34.1, 06/10/2026	Licence MIT ; validation légère de DataFrames.
Outil	Pandera, documentation des contrôles	Version stable	Les valeurs vides sont ignorées par défaut : `ignore_na=False` est nécessaire pour les contrôler.
Outil	Great Expectations, page PyPI	v1.24.0, 07/10/2026	Licence Apache 2.0 ; plateforme de validation plus complète.
Outil	GX Core, documentation	GX Core 1.x	Flux en plusieurs objets : contexte, source, lot, attentes.
Méthode	pandas, DataFrame.sort_values	Doc. en cours	Tri par défaut non stable ; `kind` ignoré sur plusieurs colonnes.
Méthode	SciPy, spearmanr	Doc. en cours	Mesure non paramétrique d'une relation monotone.
IA	Spracklen et al., USENIX Security 2025	2025	576 000 codes générés par 16 IA : au moins 5,2 % de paquets inventés pour les modèles commerciaux.
RGPD	CNIL, recommandations IA finalisées	22/07/2025	Filtrer les données personnelles autour des systèmes d'IA.
Durable	Arcep / Arcom, RGESN	17/05/2024	78 critères ; réduire les ressources mobilisées sur le cycle de vie.
Accessibilité	DINUM, RGAA 4.1.2	v4.1.2	106 critères ; alternative textuelle des images et graphiques (critères 1.1 et 1.6).
Accessibilité	W3C, WCAG 2.2	12/12/2024	Contraste 4,5:1 (1.4.3) ; jamais la couleur seule (1.4.1).
Automatisation	Google, créer une alerte	Aide en cours	Alertes livrées par e-mail ou en flux RSS, paramétrables (langue, région, sources).
Veille réglementaire	CNIL, flux RSS des actualités	Testé le 21/10/2026	Flux valide dans un navigateur, mais refusé au script (erreur 503) : remplacé par une alerte Google `site:cnil.fr`.

Automatisation

La veille tourne sans recherche manuelle, en trois couches :

- **Google Alertes** sur 7 requêtes, une fois par semaine, livrées en flux RSS. Les premiers aperçus étaient surtout du bruit, à cause d'homonymes : « Great Expectations » renvoyait au film et au sport, « Pandera » à une étape du Tour d'Espagne cycliste, la requête sur la validation de données à des offres d'emploi. Les requêtes ont donc été affinées avec des guillemets, des exclusions et des alternatives, par exemple `pandera python "data validation" -vuelta -cyclisme` et `"great expectations" ("data quality" OR "data validation" OR "data pipeline")`, puis vérifiées sur l'aperçu de chaque alerte.
- **Un script Python de veille** (`veille.py`, environ 125 lignes, sans dépendance payante) lit chaque semaine les 10 flux listés dans `sources.csv` : actualités CNIL (par l'alerte `site:cnil.fr`), publications de versions de Pandera, pandas et Great Expectations sur GitHub, et les alertes Google livrées en flux RSS. Il ajoute uniquement les nouveautés de moins de 30 jours à `journal_veille.xlsx` ; une source en panne est notée dans un journal d'erreurs sans bloquer les autres.
- **Le Planificateur de tâches de Windows** lance le script chaque lundi à 8 h : aucune action manuelle pour collecter.
- **Rythme** : 30 minutes chaque lundi pour qualifier les nouveautés (statut lu, retenu ou écarté ; pertinence de 1 à 3 ; une phrase sur l'impact). Les lignes retenues alimentent la page Veille du portfolio.

Ce choix remplace un agrégateur commercial dont les fonctions utiles demandaient un abonnement payant : la solution est gratuite, sobre (bibliothèque standard de Python et pandas) et réutilisable dans le portfolio. Le script a d'abord été testé sur des flux RSS et Atom d'exemple, avec doublons, article ancien et source en panne.

Mise en service réelle, le 21/10/2026. Au premier lancement, 9 sources sur 10 ont été lues et 10 nouveautés enregistrées ; au deuxième, aucune nouveauté n'a été ajoutée, ce qui confirme le dédoublonnage. Trois défauts sont apparus sur les flux réels, absents des flux d'exemple, et ont été corrigés :

- **Source bloquée** : le flux RSS de la CNIL, valide dans un navigateur, renvoyait une erreur au script, même présenté comme un navigateur (code 503, probablement une protection anti-robots). Le script a continué avec les autres sources et a noté l'erreur ; le bilan affiche désormais le code exact. Décision : passer par une alerte Google `site:cnil.fr`, qui couvre les mêmes actualités.
- **Titres tronqués** : Google Alertes met en gras les mots recherchés, et le script coupait le titre à ce mot (« … La » au lieu de « … La CNIL … »). Corrigé en lisant tout le texte du titre.
- **Dates factices** : Google Alertes date parfois un article du 1er janvier 1970 quand la date est inconnue. Le filtre des 30 jours l'aurait écarté sans le signaler. Corrigé : une date antérieure à 2000 est traitée comme inconnue et l'article est conservé.

Après correction, les 10 sources sont lues sans erreur.

> Preuves à joindre avant export : capture des 7 alertes Google, capture du bilan d'exécution et du journal Excel, capture de la tâche planifiée (tâche T05 du projet).

2.3 Comparatif des solutions de contrôle des données

Trois options ont été comparées sur un **vrai test** : les mêmes 10 règles (les anomalies A1 à A10 du référentiel, annexe C) écrites dans chacune, puis exécutées sur les fichiers bruts (21/10/2026, Python 3.13, pandas 2.3.3).

Critère	pandas seul	Pandera 0.34.1	Great Expectations 1.24.0
Qualité : règles exactes	10/10	10/10 (au 2e essai)	10/10
Robustesse : pièges rencontrés	Aucun	Valeurs vides ignorées par défaut ; contrôles natifs sous nom générique	Conditions multi-colonnes à exprimer en texte
Temps de validation (médiane de 5)	0,004 s	0,052 s	0,276 s
Temps d'import	—	0,43 s	2,1 s
Sobriété : paquets installés	8	18	39
Sobriété : taille installée	166 Mo	184 Mo	382 Mo

Critère	pandas seul	Pandera 0.34.1	Great Expectations 1.24.0
Maintenabilité : lignes de code	18	35	38
Règles déclaratives et rapport structuré	Non (à coder à la main)	Oui	Oui, avec documentation HTML
Courbe d'apprentissage	Faible	Moyenne	Élevée (contexte, source, lot)
Reproductibilité / sécurité	Dépend du code écrit	Schémas versionnables, exécution locale	Schémas versionnables, exécution locale

> **Choix : Pandera.** Il apporte ce qui manquait au P6 (règles déclaratives, rapport exploitable, rejouable) pour seulement 18 Mo et 10 paquets de plus que pandas, contre 216 Mo et 31 paquets pour Great Expectations, qui est aussi 5 fois plus lent. Great Expectations se justifierait pour une plateforme de données multi-sources avec une équipe dédiée, pas pour un notebook d'analyse. pandas seul reste le plus rapide, mais c'est précisément la dispersion des contrôles à la main qui a produit les erreurs du P6.

2.4 Méthodes d'analyse retenues

Méthode	Pourquoi	Avantage par rapport au P6
Corrélation de Spearman en plus de Pearson	Distributions très asymétriques (prix jusqu'à 225 €)	Mesure la relation monotone ; corrige la conclusion du P6 sur stock et ventes.
Matrice ABC × couverture de stock	Croiser importance commerciale et immobilisation	Montre où agir : surstock en classe A, ruptures sur des références A.
Analyse de sensibilité (H1 / H2)	La période de `total_sales` est inconnue	Rend l'hypothèse explicite au lieu de la cacher.
Ordre de tri entièrement déterminé	Le tri par défaut de pandas n'est pas stable	Mêmes résultats quelle que soit la version.
Assertions de non-régression	Les chiffres du CODIR ne doivent pas bouger sans raison	Le notebook s'arrête si un indicateur communiqué change.

2.5 Pistes d'amélioration continue

- Écrire les tests automatisés du module de contrôle (`pytest`), une règle bloquante par test.
- Obtenir un historique mensuel des ventes pour passer à la classification XYZ et au calcul de stocks de sécurité.
- Planifier l'exécution du contrôle à chaque export, et suivre l'évolution du nombre d'anomalies BLOQUANT.

3. Cahier des charges fonctionnel

3.1 Contexte et parties prenantes

BottleNeck vend en ligne vins, champagnes, spiritueux et huiles d'olive. Ses données vivent dans trois sources hétérogènes : l'ERP (825 produits), l'export du site WooCommerce (1 513 lignes, un produit et son image par article) et une table de liaison tenue à la main (825 lignes). L'environnement est **complexe et changeant** : migration ERP en cours, exports répétés dont le format peut évoluer, table de liaison modifiée manuellement, outils d'IA dont les modèles et les quotas changent d'un mois à l'autre, et un cadre réglementaire (RGPD, recommandations CNIL sur l'IA) qui se précise.

Partie prenante	Utilise l'analyse pour…	Attente principale
Direction	Décider du déstockage et valider la migration ERP	Indicateurs fiables, impact financier chiffré
Responsable stock / achats	Ajuster les réapprovisionnements	Couverture de stock par référence, ruptures
Équipe commerciale	Corriger prix et mises en vente	Liste des anomalies de prix et de statut
Gestionnaire du site WooCommerce	Corriger fiches et codes article	Doublons, sku manquants, fiches orphelines
IT / chef de projet ERP	Contrôler chaque export avant chargement	Contrôle automatique et rejouable
Référent RGPD	Encadrer le partage des données	Aucune donnée personnelle exposée

3.2 État actuel

Constats de l'audit du P6, tous vérifiés par script sur les fichiers bruts :

- Contrôles écrits cellule par cellule et récapitulatif saisi en dur, avec des écarts (4 ventes à perte annoncées, 7 calculées).
- Contrôle de jointure faux : `product_id` comparé à `sku`, deux clés sans rapport.
- `13127-1` et le bon cadeau déclarés « exclus par la jointure » : ils figurent dans le jeu final ; le bon cadeau, sans famille, disparaissait du CA par famille.
- Couverture de stock calculée sur 12 mois sans le dire ; produits sans vente et stock hors vente absents de l'analyse.
- Corrélations de Pearson sur des distributions asymétriques ; classement des ventes différent entre pandas 2 et 3.

3.3 Problématique reformulée

> Comment garantir que chaque export ERP, site et liaison est contrôlé automatiquement avant la migration, et que l'analyse de stock et de ventes qui en découle est fiable, reproductible et utilisable pour décider d'un plan de déstockage ?

3.4 Objectifs, enjeux et priorités

Priorité	Objectif	Enjeu
1 — Must	Contrôle qualité automatique, gravité BLOQUANT / ALERTE, rapport Excel	Ne pas charger de données fausses dans le nouvel ERP
1 — Must	Corriger les erreurs du P6 sans changer les chiffres validés au CODIR	Crédibilité de l'analyse auprès de la direction
2 — Must	Chiffrer le stock immobilisé (dormant, hors vente, surstock)	Trésorerie
2 — Should	Rendre explicites les hypothèses et leur sensibilité	Décisions prises en connaissance de cause

Priorité	Objectif	Enjeu
3 — Should	Reproductibilité (versions, tri, assertions)	Analyse rejouable par un tiers
3 — Could	Tests automatisés du module	Industrialisation

3.5 Périmètre

Inclus	Exclu
Les 3 fichiers du P6 (ERP, site, liaison), tels que livrés	Autres sources (comptabilité, fournisseurs, historique de commandes)
Contrôle qualité, nettoyage tracé, jointure vérifiée	Correction des données dans l'ERP ou le site (décision métier)
CA, Pareto, ABC, stocks, couverture, marges, corrélations	Prévision de la demande et stock de sécurité (pas d'historique mensuel)
Comparaison de 2 IA et de 3 approches de contrôle	Mise en production automatisée

3.6 Contraintes

- **Données** : période de `total_sales` inconnue ; 91 produits sans `id_web` ; 20 `id_web` orphelins ; 83 lignes du site sans sku ni type.
- **RGPD** : `post_author` et `guid` peuvent identifier des personnes ; aucune ligne de données n'est transmise aux IA.
- **Outillage** : Python et Jupyter sous Windows (Anaconda), librairies libres ; IA utilisées via les abonnements existants.
- **Délais** : 4 semaines à temps plein, du 28/09 au 25/10/2026, soutenance ensuite.

3.7 Spécificités fonctionnelles

Fonction	Description
F1 · Contrôler	Valider les 3 fichiers bruts avec 64 règles ; sortie : fichier, règle, colonne, ligne, valeur, niveau.
F2 · Rapporter	Générer `rapport_qualite_donnees.xlsx` (synthèse + détail, ligne Excel indiquée).
F3 · Nettoyer	Appliquer les corrections désignées par les règles et les tracer dans un journal.
F4 · Joindre	Assembler les sources par la table de liaison ; s'arrêter si une clé casse.
F5 · Analyser	CA, Pareto, ABC, couverture (H1, H2), stock dormant, marges, corrélations.
F6 · Garantir	Vérifier que les indicateurs du CODIR sont inchangés ; afficher les versions.

3.8 Ressources et budget

- **Humaines** : une data analyst (porteuse du projet), un mentor (3 séances prévues à temps plein).
- **Charge** : 140 h prévues par la formation (70 h encadrées, 70 h personnelles) ; le backlog Airtable estime 81 h de tâches.
- **Outils** : Python, pandas, Pandera, matplotlib et Jupyter (open source, 0 €) ; Airtable pour le pilotage ; Claude et Gemini via des abonnements déjà souscrits. Coût logiciel supplémentaire : 0 €.
- **Valorisation indicative** : 81 h, soit environ 11,6 jours ; à un taux journalier de 450 € HT (hypothèse pour un profil junior, à ajuster), environ 5 200 € HT.

3.9 Livrables et planning

Jalon	Date	Critère de validation	Statut au 21/10
J1 · Cadrage et audit du P6	28/09/2026	P6 réexécuté, constats vérifiés	Atteint
J2 · Protocole de test IA figé	28/09/2026	Prompts et grille fixés avant tout essai	Atteint
J3 · Essais notés, décision	20/10/2026	6 essais au banc, grille sur 100	Atteint
J4 · Notebook amélioré (livrable 1)	20/10/2026	Exécution complète, assertions OK	Atteint
J5 · Documentation PDF (livrable 2)	22/10/2026	Indicateurs de la grille couverts	En cours
J6 · Portfolio (livrable 3)	24/10/2026	≥ 10 projets, veille intégrée	À venir
J7 · Dépôt des livrables	25/10/2026	Zip conforme à la convention	À venir
J8 · Soutenance	À confirmer	15 min ± 5, discussion, débrief	À venir

3.10 Critères de réussite et d'acceptation

Type	Critère	Cible	Résultat mesuré
Données	Anomalies du référentiel détectées	9/9	9/9 (module) ✔️
Données	Fausses erreurs bloquantes	0	0 ✔️
Données	Lignes BLOQUANT avant chargement ERP	0	197 à corriger par le métier
Insights	Indicateurs CODIR inchangés (714 réf., CA 143 680,10 €, stock 277 328,07 €)	Identiques	Identiques (assertions) ✔️
Insights	Hypothèses de calcul explicites	100 %	Période H1 / H2 documentée ✔️
Opérationnel	Durée d'exécution complète	< 30 s	8 s ✔️
Opérationnel	Reproductibilité entre versions	Sorties identiques	pandas 2.3 et 3.0 identiques ✔️
Opérationnel	Données personnelles envoyées à une IA	0 ligne	0 ligne ✔️

4. Organisation et pilotage du projet

Le projet est piloté dans une base Airtable, **P13 · Pilotage projet BottleNeck**, avec trois tables liées : Tâches (backlog et Kanban), Jalons et Risques.

4.1 Découpage en lots et backlog

Lot	Tâches	Points	Charge (h)	Avancement au 21/10
L1 Cadrage & veille	T01–T05	11	14	3 terminées, 1 en cours, 1 à faire
L2 Cahier des charges	T06–T07	5	6	En cours
L3 Protocole & essais IA	T08–T13	18	16,5	Terminé
L4 Notebook amélioré	T14–T17	14	12	3 terminées, T17 (Could) à faire
L5 Documentation PDF	T18–T19	11	11	En cours
L6 Portfolio	T20–T22	12	14	À faire
L7 Soutenance	T23–T25	8	7,5	À faire
Total	25 tâches	79	81	12 terminées

Chaque tâche porte : un type (user story ou tâche technique), une priorité MoSCoW, une complexité en points (suite 1, 2, 3, 5, 8), une charge en heures, des dates, ses **dépendances** (champ lié, par exemple T12 « Noter les 6 essais » dépend de T09, T10 et T11) et une **définition de Done** vérifiable. Exemple de user story : « En tant qu'équipe BottleNeck, je veux un contrôle rejouable à chaque export, pour ne pas charger de données fausses dans le nouvel ERP » (T14) ; Done : module validé au banc (9/9), rapport Excel généré.

> Capture du Kanban Airtable (vue groupée par Statut) à insérer ici avant export : elle est la preuve demandée par la grille.

4.2 Points de contrôle et versioning

- **Revues** : 3 séances mentor (cadrage, après les essais, avant le dépôt).
- **Validations intermédiaires** : banc de test validé par des témoins (10/10 et 0/10) avant toute note ; assertions de non-régression à chaque exécution du notebook.
- **Versioning** : historique du document de protocole, journal des essais horodaté, archives des réponses IA brutes, `requirements.txt` ; dépôt GitHub prévu (T20).

4.3 Registre des risques

ID	Risque	P × I	Prévention	Statut
R01	Code IA qui ne tourne pas (fonction inventée)	3 × 3	Banc de test sur données brutes	Survenu (G-P1)
R02	Code IA juste en apparence mais faux	3 × 3	Comparaison à un référentiel recalculé	Survenu (G-P2, G-P2bis)
R03	Évaluateur juge et partie (Claude note Claude)	2 × 3	Instances vierges, grille fixée avant, témoins	Maîtrisé
R04	Référentiel biaisé	2 × 2	Recomptage par script, trouvailles vérifiées	Survenu, corrigé
R05	Réponses IA non reproductibles	3 × 2	Relance P2bis, indice de Jaccard	Survenu
R06	Fuite de données personnelles vers une IA	2 × 3	Noms de colonnes seulement, chat temporaire, RGPD-01	Maîtrisé
R07	Période des ventes inconnue	3 × 3	Hypothèses H1 / H2, sensibilité	Ouvert

ID	Risque	P × I	Prévention	Statut
R08	Seuils arbitraires instables	2 × 2	Seuils calculés (IQR)	Maîtrisé
R09	Dérive du format des exports	2 × 3	Contrôles rejouables, assertions	Ouvert
R10	Résultats différents selon les versions	2 × 2	Tri déterminé, versions affichées	Maîtrisé
R11	Quota d'usage IA atteint	2 × 2	3 essais le même jour, même modèle	Maîtrisé
R12	Retard sur 4 semaines	2 × 3	MoSCoW, Could reportés	Ouvert

5. POC : amélioration du P6 avec l'IA

5.1 Hypothèses

- **H-IA** : donner le contexte métier dans le prompt améliore davantage les règles de contrôle que le choix de l'outil.
- **H-OUTIL** : une librairie de validation déclarative fiabilise le contrôle sans coût de calcul ni d'installation excessif.

5.2 Protocole

Deux outils (Claude, modèle claude-opus-5-5 ; Gemini 4 Argon) × deux prompts (P1 simple, P2 enrichi d'un dictionnaire de données et de règles de gestion, annexe B) + une relance de P2 par outil = **6 essais**. Règles : conversation neuve sans mémoire (chat temporaire pour Gemini, instances Claude au contexte vierge), prompt copié mot pour mot, un seul tour, **aucune ligne de données envoyée**, réponse sauvegardée brute, modèle et heure notés (annexe A).

Chaque code est exécuté **tel quel** sur les fichiers bruts par un banc de test (Python 3.13, pandas 2.3.3, pandera 0.34.1), qui compare les lignes signalées au référentiel (annexe C) : 9 anomalies vérifiées, 5 contrôles qui doivent passer, et 4 trouvailles hors référentiel vérifiées après coup. Le banc a été validé par des témoins : code parfait 10/10, code vide 0/10, code cassé détecté en échec.

5.3 Résultats

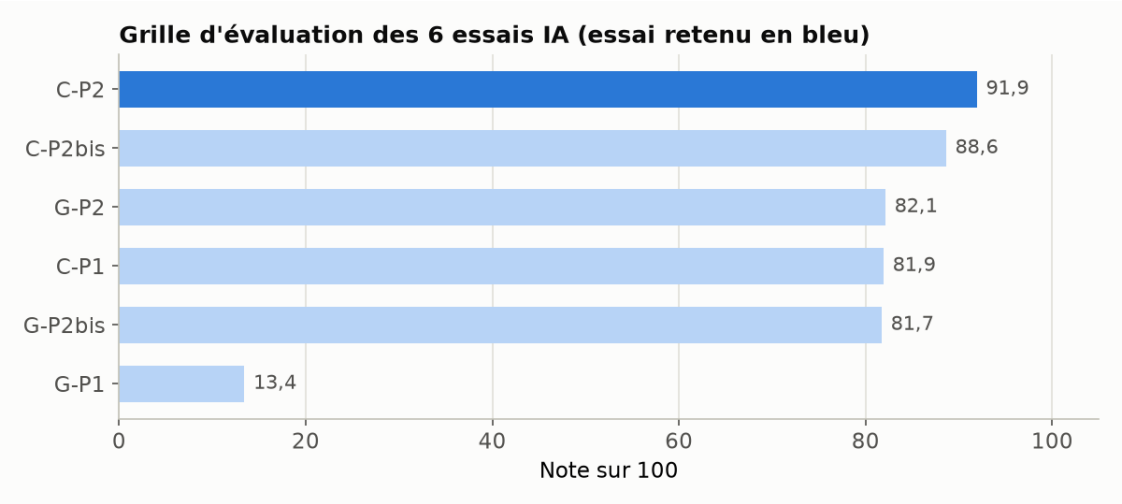


Figure 1 — Note sur 100 des 6 essais (grille de l'annexe D)

Essai	Tourne tel quel	Détection /9	Trouvailles /4	Gravité en sortie	Total /100
C-P2	Oui	9	3	Oui	91,9
C-P2bis	Oui	8	4	Oui	88,6
G-P2	Oui	9	3	83 lignes sur 301	82,1
C-P1	Oui	8	1	Non	81,9
G-P2bis	Oui	7	2	80 lignes sur 85	81,7
G-P1	Non (fonction inventée)	0 (8 après correction)	0	Non	13,4

Reproductibilité : indice de Jaccard moyen entre P2 et P2bis de 0,795 pour Claude et 0,559 pour Gemini ; pour un même prompt, Gemini fixe un plafond d'alerte à 1 000 € puis à 5 000 €.

5.4 Constats qualitatifs

- **Hallucination d'API (G-P1)** : `Check.notna` n'existe dans aucune version de Pandera, de la 0.14 à la 0.34 (vérifié). C'est le phénomène mesuré à grande échelle par Spracklen et al. (2025).
- **Défauts invisibles à la lecture** : G-P2 perd le niveau de gravité pour 218 lignes sur 301 ; G-P2bis laisse passer 83 lignes vides, car Pandera ignore les valeurs vides par défaut.
- **Apport réel de l'IA** : les règles ont révélé des anomalies que l'audit humain avait manquées (produits en vente sans `id_web`, stock hors vente, produit hors vente publié).
- **Limite commune** : aucune des 6 réponses ne signale les colonnes personnelles `post_author` et `guid`.

5.5 Décisions : ce qui est gardé, ce qui est écarté

Gardé	Écarté
Le code de C-P2, figé dans `controles_qualite.py`	Les seuils fixes de Gemini (sans source, instables)
ERP-22 (stock hors vente), idée de C-P2bis	La règle « post_type doit valoir product » (faux positif sur 714 images)
Seuil de prix calculé sur les données (IQR), en alerte seulement	Toute règle de valeur obligatoire qui ignore les cellules vides
Ajouts humains : RGPD-01 (données personnelles), WEB-28 (fiches en double)	Les propositions de suite de Gemini (hors protocole à un tour), reportées au backlog

5.6 Ce que change le notebook amélioré

Le livrable 1 reprend la structure du P6 et intègre ces décisions. Il signale **325 anomalies** (197 BLOQUANT, 128 ALERTE) sur 17 des 64 règles, corrige quatre erreurs du P6 (contrôle de jointure, statut de `13127-1` et du bon cadeau, recommandation de renommer `13127-1`, conclusion sur le lien entre stock et ventes) et ajoute une lecture financière du stock.

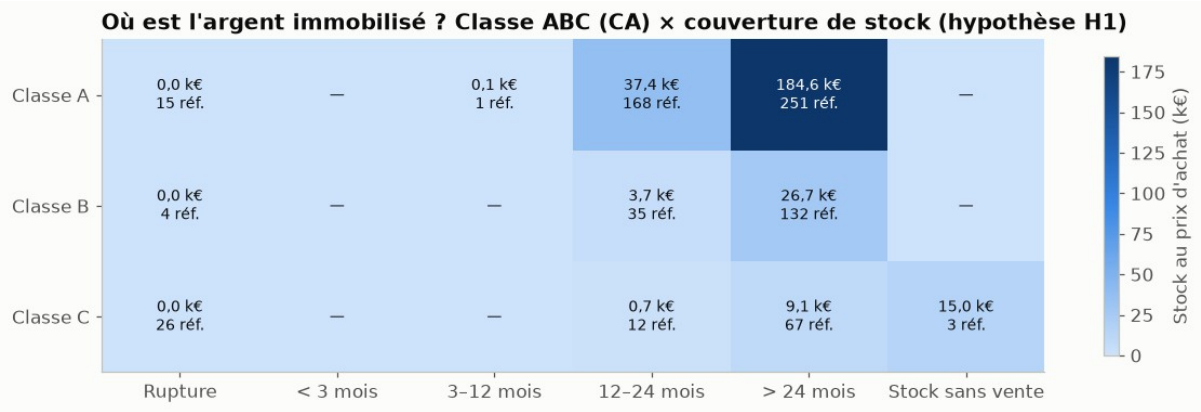


Figure 2 — Stock au prix d'achat par classe ABC et couverture (hypothèse H1)

- **Stock et ventes** : Spearman 0,76 au lieu de 0,44 en Pearson ; le P6 concluait à tort que « le stock n'est pas lié aux ventes passées ».
- **Surstock** : 450 références dépassent 24 mois de couverture sous H1 (79,5 % de la valeur du stock) et 600 sous H2.
- **Stock dormant** : 65 produits hors vente (21 403 €) et 3 produits en vente sans aucune vente (14 959 €), absents du P6.
- **Fiches en double** : `13127-1` double la fiche `16034` (même vin 2007, même prix) ; le P6 proposait de le renommer `13127`, qui est le millésime 2012.

La seconde hypothèse est également confirmée : Pandera détecte les 10 règles du test en n'ajoutant que 18 Mo à l'installation de pandas, contre 216 Mo pour Great Expectations (section 2.3).

6. Mini-plan de formation

Objectif : que chaque équipe sache lire le rapport qualité et agir sur ce qui la concerne, sans dépendre de l'analyste. Le plan est conçu pour des publics non techniques, **y compris des collaborateurs en situation de handicap**.

Module	Public	Durée	Contenu	Évaluation
M1 · Lire le rapport qualité	Tous	45 min	Pourquoi contrôler ; onglets Synthèse et Détail ; BLOQUANT ou ALERTE ; retrouver la ligne Excel	Quiz de 5 questions
M2 · Traiter une anomalie	Stock, commercial, site	1 h	Cas réels : prix négatif, stock négatif, fiche en double, stock hors vente ; qui corrige quoi	Corriger 3 anomalies du rapport
M3 · Décider avec la matrice ABC	Direction	45 min	Lire la matrice ABC × couverture ; hypothèses H1 / H2 ; arbitrer un déstockage	Décision argumentée sur 2 cas
M4 · Faire vivre le contrôle	IT / data	1 h 30	Relancer le notebook ; ajouter une règle Pandera ; pièges connus (valeurs vides, noms des contrôles)	Ajouter une règle testée

6.1 Accessibilité des supports et des séances

- **Information jamais portée par la couleur seule** (WCAG 1.4.1) : le niveau BLOQUANT ou ALERTE est écrit en toutes lettres dans le rapport et sur les graphiques.
- **Contraste d'au moins 4,5:1** pour le texte (WCAG 1.4.3), police d'au moins 12 points sur les fiches, palette de graphiques testée pour les daltoniens.
- **Alternative textuelle** pour chaque graphique (RGAA, critères 1.1 et 1.6), comme dans ce document ; tableaux Excel avec en-têtes de colonnes, lisibles par un lecteur d'écran.
- **Vidéo de 5 minutes sous-titrée** et transcription, pour revoir M1 à son rythme ; séances enregistrées.
- **Aménagements à la demande** : temps majoré pour les exercices, travail en binôme, choix entre présentiel et distanciel, supports envoyés 48 h avant.

6.2 Indicateurs de réussite

- 100 % des participants au M1 savent distinguer BLOQUANT et ALERTE (quiz).
- Nombre de lignes BLOQUANT divisé par deux deux semaines après la formation, puis zéro avant le chargement ERP.

7. Limites, biais et risques résiduels

- **Période des ventes inconnue** : toutes les couvertures dépendent de l'hypothèse H1 ou H2 ; aucune décision de déstockage ne doit être prise avant validation par BottleNeck.
- **Taille du test IA** : un seul jeu de données, deux essais par prompt et par outil ; les écarts de quelques points entre essais ne sont pas significatifs.
- **Conditions d'essai** : les essais Claude ont été passés par des instances au contexte vierge et non dans l'interface claude.ai ; les durées de réponse de Gemini n'ont pas été chronométrées.
- **Référentiel corrigé en cours de route** : A9 reclassée (un `id_web` vide est légitime pour un produit hors ligne), N1 à N4 ajoutées après vérification ; tous les essais ont été recalculés avec la même règle.
- **Jugement résiduel** : la note de maintenabilité repose sur une grille de lecture justifiée critère par critère, mais reste un jugement.
- **Règles produites par une IA** : retenues sur mesures, mais leurs seuils et listes de valeurs restent à faire valider par le métier ; le seuil « prix atypique » n'est qu'une alerte.
- **Veille dépendante de Google** : 7 des 10 sources passent par Google Alertes, qui choisit seul les résultats et peut modifier son service ; les sources GitHub restent lues directement. Les adresses des flux d'alertes contiennent un identifiant personnel et ne sont pas publiées dans le portfolio.

8. Reproductibilité

Élément	Valeur
Environnement de référence	Python 3.13.13, pandas 2.3.3, numpy 2.5.4, pandera 0.34.1, matplotlib 3.11.2, openpyxl 3.1.5
Deuxième environnement testé	Python 3.11, pandas 3.0.2 : sorties identiques
Aléatoire	Aucun (pas de tirage) ; ordre des tris entièrement déterminé
Structure	Notebook + `controles_qualite.py` + 3 fichiers Excel bruts + `requirements.txt` + `LISEZMOI.md`
Exécution	`pip install pandera`, puis Noyau → Redémarrer et tout exécuter (8 s)
Garde-fous	Assertions de jointure et de non-régression : le notebook s'arrête si un chiffre du CODIR change
Traces des essais	Réponses brutes, codes, anomalies, grille et banc de test dans `P13_essais_IA.zip`

9. Synthèse pour le client

Résultat. BottleNeck dispose d'un contrôle qualité automatique de ses trois sources, d'une analyse corrigée et rejouable, et d'une vision chiffrée de son stock immobilisé.

Impact. La migration ERP peut être sécurisée (aucun chargement tant qu'il reste une anomalie bloquante) ; 21 403 € de stock hors vente et 14 959 € de stock sans vente sont identifiés ligne par ligne ; le surstock de la classe A (184,6 k€) devient un sujet de pilotage.

Recommandations, par priorité.

1. Brancher `controles_qualite.py` en contrôle d'entrée de la migration et corriger les 197 lignes BLOQUANT.
2. Corriger le prix du Champagne Egly-Ouriet Blanc de Noirs (12,65 € pour 77,48 € d'achat) et trancher les 3 paires de fiches en double.
3. Lancer le plan de déstockage à partir de la matrice ABC × couverture, après validation de la période des ventes.
4. Pseudonymiser `post_author` et `guid` avant tout partage externe.
5. Former les équipes avec les modules M1 à M4.

Prochaines étapes : tests automatisés du module, historique mensuel des ventes pour la classification XYZ et le stock de sécurité, exécution planifiée du contrôle à chaque export.

Gestion du projet : 12 tâches sur 25 terminées au 21/10, 4 jalons atteints sur 8, livraison prévue le 25/10/2026.

Annexes

A. Journal des essais IA

Essai	Modèle	Date	Durée de réponse	Observation principale
C-P1	claude-opus-5-5 (instance vierge)	18/10/2026	230 s	Prévient qu'il n'a pas testé le code ; pas de niveau de gravité.
C-P2	claude-opus-5-5 (instance vierge)	18/10/2026	418 s	BLOQUANT / ALERTE, 15 hypothèses ; id_web vide traité comme légitime.
C-P2bis	claude-opus-5-5 (instance vierge)	18/10/2026	336 s	Code différent de C-P2 ; ajoute « stock > 0 mais hors vente ».
G-P1	Gemini 4 Argon (chat temporaire)	20/10/2026	Non chronométrée	Fonction inventée `Check.notna` ; aucune hypothèse.
G-P2	Gemini 4 Argon (chat temporaire)	20/10/2026	Non chronométrée	Gravité perdue en sortie ; seuils fixes sans source ; 5,8 s d'exécution.
G-P2bis	Gemini 4 Argon (chat temporaire)	20/10/2026	Non chronométrée	Seuils différents de G-P2 ; famille « Autre » ajoutée.

B. Prompts

P1 (simple) : décrit les trois fichiers (noms et types des colonnes) et le format de rendu imposé — une fonction `valider(erp, web, liaison)` renvoyant les anomalies (fichier, règle, colonne, index de ligne, valeur), sans s'arrêter à la première erreur et sans inventer de données.

P2 (enrichi) : reprend P1 et ajoute un rôle (data analyst en cabinet de conseil), le contexte de BottleNeck et de sa migration ERP, un dictionnaire de données avec les règles de gestion (statut de stock, structure produit / image du site, rôle de la table de liaison, `id_web` vide possible, produits premium légitimes), et quatre attentes : règles par fichier et entre fichiers, justification métier de chaque règle, distinction bloquant / alerte, liste des hypothèses. Les deux textes complets figurent dans le document de protocole et dans l'archive des essais.

C. Référentiel des anomalies

N°	Fichier	Anomalie	Lignes
A1	ERP	stock_status incohérent avec stock_quantity	2
A2	ERP	Prix de vente nul ou négatif	3
A3	ERP	Stock négatif	2
A4	ERP	Prix positif inférieur au prix d'achat	4
A5	Site	sku manquant	85
A6	Site	Ventes cumulées négatives	2
A7	Site	sku non numérique	4
A8	Site	post_type vide ou inattendu	83
A9	Liaison	id_web manquant (contestable, hors score)	91
A10	Liaison / site	id_web orphelin	20
N1	ERP / liaison	Produit en vente sans id_web	3
N2	Site	Produit sans famille	1
N3	ERP	Stock positif mais hors vente	65

N°	Fichier	Anomalie	Lignes
N4	ERP / liaison	Produit hors vente mais publié	1

Contrôles qui doivent passer : unicité de `product_id` (T1), unicité du sku parmi les produits (T2, piège des 714 images), unicité de `id_web` (T3), `product_id` de la liaison présents dans l'ERP (T4), prix premium sans erreur bloquante (T5).

D. Règles de notation

Critère	Poids	Calcul
Qualité	30	30 × anomalies détectées / 9 (une règle doit retrouver toutes les lignes, avec une précision d'au moins 50 %)
Robustesse / biais	15	15 si aucune fausse erreur bloquante, 0 si le code ne tourne pas
Exécution	15	15 si le code tourne sans modification, 0 sinon
Reproductibilité	15	15 × moyenne des indices de Jaccard (anomalies et lignes) entre P2 et P2bis
Sécurité / conformité	10	5 pour tous : aucune donnée envoyée, aucune colonne personnelle signalée
Maintenabilité	10	10/3 par critère : justification de chaque règle, hypothèses listées, gravité exploitable
Temps et sobriété	5	5 si exécution médiane < 1 s, 2 au-delà, 0 si le code ne tourne pas

E. Glossaire

Terme	Définition
Pandera	Librairie Python de validation de tableaux de données par schémas déclaratifs.
Banc de test	Script qui exécute chaque code IA sur les mêmes données et le note automatiquement.
Indice de Jaccard	Part des éléments communs à deux ensembles (de 0, rien en commun, à 1, identiques).
Classe ABC	A : références qui font 80 % du CA ; B : jusqu'à 95 % ; C : le reste.
Couverture de stock	Nombre de mois de ventes que le stock actuel permet de servir.
Hallucination	Contenu plausible mais faux produit par une IA (ici, une fonction qui n'existe pas).